




# Prevención de fraude:

## ML y patrones de diseño

mantén a tus analistas en el loop

# Material de la charla

Repositorio de GitHub



[https://github.com/jospablo777/fraud\\_ml\\_design\\_pattern](https://github.com/jospablo777/fraud_ml_design_pattern)

Contacto (LinkedIn)



<https://www.linkedin.com/in/jose-barrantes/>

# Contenido

1. Fraude como problema de arquitectura

2. Por qué no basta un solo componente

3. El patron: ML + analistas + reglas

4. Blueprint para aplicarlo manana

# Con esta charla queremos

- Desarrollar un **lenguaje en común**
- Pensar el **fraude como problema de arquitectura**, no solo de modelos predictivos
- Motivar a **diseñar mejores sistemas** antifraude con *machine learning* (ML) y humanos expertos



# Vamos a hablar de

- Prevención de fraude
- **Arquitectura** de software con ML (*ML-enabled software*)
- El **rol de analistas expertas** en la efectividad del sistema

**No es una charla sobre algoritmos, sino sobre diseño de sistemas**

# Imaginen




# Imaginen que..

20 casos entran ahora mismo

- No pueden revisarlos todos
- No pueden bloquearlos todos

## ¿Qué harían?



# El sistema ML los clasifica así

- 10 bajo riesgo
- 5 ambiguos
- 5 alto riesgo




# Revisar todo manualmente no escala

Cada caso, en promedio tarda **1 hora** analista en ser procesado.

- Inversión: **20 horas** analista
- **Mayor juicio contextual**



**20 hrs**





# El valor de la detección de fraude es una función del tiempo





*Cada minuto de demora puede aumentar el costo del fraude*

(Hilal, Gadsden & Yawney, 2022)

# Automatizar demasiado también sale caro

El sistema de ML clasifica cada caso en menos de **1 milisegundo** (ms).

- Inversión: **<1 minuto**
- **Rápido**, sí
- Pero **más fricción** y dejamos pasar más **patrones novedosos**






# La alternativa: combinar ML + analistas

**Híbrido:** automatizar lo claro y elevar lo ambiguo

- Reducción de 20 a 5 horas de revisión humana
- De **inmediato** accionamos lo crítico
- Lo mejor de ambos mundos

**<1 min**

Bajo riesgo



Dejar pasar automáticamente

**5 hrs**


Ambiguos



Enviar a revisión humana

**<1 min**

Alto riesgo



Retener automáticamente



# ¿Qué gana la organización con un diseño híbrido?

- **Menos fricción** para usuarios legítimos
- **Mejor uso** del **talento experto**
- **Menor costo** por **demora**

Bajo riesgo



Ambiguos



Alto riesgo



***Si bloqueas de más, pierdes clientes.***



***Si bloqueas de menos, pierdes dinero.***



***Si revisas todo manualmente, no escalas.***




# Fraude



# ¿Por qué el fraude es especialmente difícil?

- Los atacantes se adaptan
- El fraude es raro y las etiquetas imperfectas
- Hay que decidir en tiempo real
- El comportamiento cambia con el tiempo
- Además: explicabilidad y cumplimiento

# El fraude es adversarial: el atacante se adapta




Fraude **no es un problema estático**. Cuando un detector funciona, **los atacantes cambian su estrategia**. Por eso no basta con entrenar un modelo “bueno” una vez

(Bolton & Hand, 2002; Lunghi et al., 2023)



# El fraude es raro y las etiquetas son imperfectas

- La mayoría de los casos son legítimos. Eso hace que el problema esté fuertemente **desbalanceado**.
- Muchas veces no hay *labels* perfectos o suficientes para entrenar.



(Hilal, Gadsden & Yawney, 2022; Chen et al., 2025)

# Hay que decidir rápido, pero los errores cuestan distinto

- No todos los errores cuestan lo mismo.
- Un falso negativo **deja pasar** fraude real.
- Un falso positivo mete **fricción**, costo operativo y mala experiencia.
- Además, **no hay tiempo infinito** para investigar.



(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022)

# No basta con *accuracy*: explicabilidad, privacidad y cumplimiento


- Explicar decisiones
- Respetar regulaciones de privacidad
- Operar bajo controles de gobernanza y auditoría



(Hernandez Aros et al., 2024; Chen et al., 2025)




El fraude no es sólo un problema de predicción; es un problema de **decisión operativa bajo incertidumbre**



# Ni reglas, ni ML, ni revisión humana bastan por sí solos

El fraude es un problema de sistema, no de una pieza aislada



# Solo reglas

## Aportan:

- Respuesta inmediata
- Simplicidad
- Auditabilidad

## Pero no bastan:

- Son rígidas
- Se vuelven fáciles de evadir
- Requieren mantenimiento continuo



(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022;  
Ding et al., 2023)


# Solo *machine learning* (ML)

## Aporta:

- Escala
- Velocidad
- Consistencia

## Pero no basta:

- Puede ser difícil de explicar
- Es sensible al *drift* y a tácticas nuevas
- Puede aumentar fricción sobre usuarios legítimos



(Hilal, Gadsden & Yawney, 2022; Lunghi et al., 2023;  
Chen et al., 2025)

# Solo analistas

## Aportan:

- Juicio contextual
- Detección de patrones novedosos
- Mejor manejo de la zona gris

## Pero no bastan:

- No escala
- Es costoso
- Introducen demoras operativas



(Amershi et al., 2019; Zelvenskiy et al., 2022; Ding et al., 2023; Mosqueira-Rey et al., 2023)




La pregunta ya no es qué componente elegir.  
La pregunta es cómo hacerlos **trabajar juntos**.




# Un sistema con ML no es solo un modelo

- **ML:** scoring, predicción
- **Software tradicional:** APIs, reglas, integración, gestión de casos
- **Infraestructura/plataforma:** monitoreo, gobernanza, despliegue, automatización



(Sculley et al., 2015; Lewis, Ozkaya & Xu, 2021; Kästner 2025)

# En producción, el modelo vive rodeado de infraestructura, operaciones, software convencional y **expertos humanos**



(Sculley et al., 2015; Lewis, Ozkaya & Xu, 2021; Kästner 2025)



# Planeamiento y arquitectura

Los **componentes** se deben de planear en conjunto desde la fase de **arquitectura**, no en secuencia ni de manera aislada.




Figura construida a partir de Lewis, Ozkaya & Xu (2021), de Andersen, & Maalej (2024), y de Kästner (2025)

# El humano como componente arquitectónico

- **Asistencia a decisión:** la máquina ayuda a decidir rápido
- **Triage de casos ambiguos:** los casos inciertos se escalan a revisión
- **Aprendizaje continuo:** el *feedback* humano mejora el sistema

**El *HIL* no es un parche; es una decisión arquitectónica**

(Zelvenskiy et al., 2022; Mosqueira-Rey et al., 2023;  
Andersen & Maalej, 2024)

# La sinergia entre ML y expertas no es opcional

## ML:

- Escala
- Priorización
- Velocidad

→ Prioriza qué mirar

## Analistas:

- Contexto
- Validación
- Juicio

→ Corrigen y enseñan

## Sistema:

- Nuevas reglas
- Calibración
- Aprendizaje continuo

→ Mejora el siguiente ciclo

**El *HIL* en fraude no es una concesión; es una estrategia de desempeño y adaptación**

(Chai et al., 2020; Mosqueira-Rey et al., 2023; Ding et al., 2023; Andersen & Maalej, 2024; Yuan et al., 2026)

# Patrón *human-in-the-loop* (HIL) para prevención de fraude



# Patrones de diseño

*Una solución reusable a un problema común dentro de un contexto específico*

O una plantilla adaptable para resolver un problema recurrente




(Lakshmanan et al., 2020; Konieczny, 2025)




# Patrones de diseño

## Recursos


- Reciente interés de expandirlos a la “ciencia de datos”




(Gamma et al., 1995)



(Lakshmanan et al., 2020)



(Konieczny, 2025)



# Patrones de diseño

- Adaptables
- Reusables
- Responden a un problema específico
  - Por ejemplo, el fraude ocurre en muchas compañías y productos.
- Nos ahorran tiempo
- Son generales: no proveen detalles de implementación



(Lakshmanan et al., 2020; Konieczny, 2025)

# Nuestro patrón de diseño

*ML-enabled Human-in-the-loop (HIL) Triage*





# Patrón: *ML-enabled HIL Triage*

- **Problema:** ¿Cómo tomar decisiones antifraude **rápidas** sin sacrificar **juicio** en los casos que más importan?
- **Contexto:** Sistemas donde el volumen supera la capacidad humana, pero automatizar todo introduce puntos ciegos.



# *ML-enabled Human-in-the-loop Triage*

- **Solución:**

Clasificar casos por bandas de riesgo y asociar una política de acción:

- **bajo riesgo** → automatización favorable
- **alto riesgo** → mitigación automática
- **zona gris** → revisión humana



# *ML-enabled Human-in-the-loop Triage*

- **Consecuencias:**
  - Mejor uso del talento experto
  - Menor fricción innecesaria
  - Mayor capacidad de adaptación.
  - Mayor complejidad operacional
- **Por qué funciona?**

Alinea cada tipo de decisión con el recurso más adecuado:


- reglas → condiciones explícitas
- *ML* → priorización a escala
- analistas → incertidumbre contextual



# Anatomía del sistema

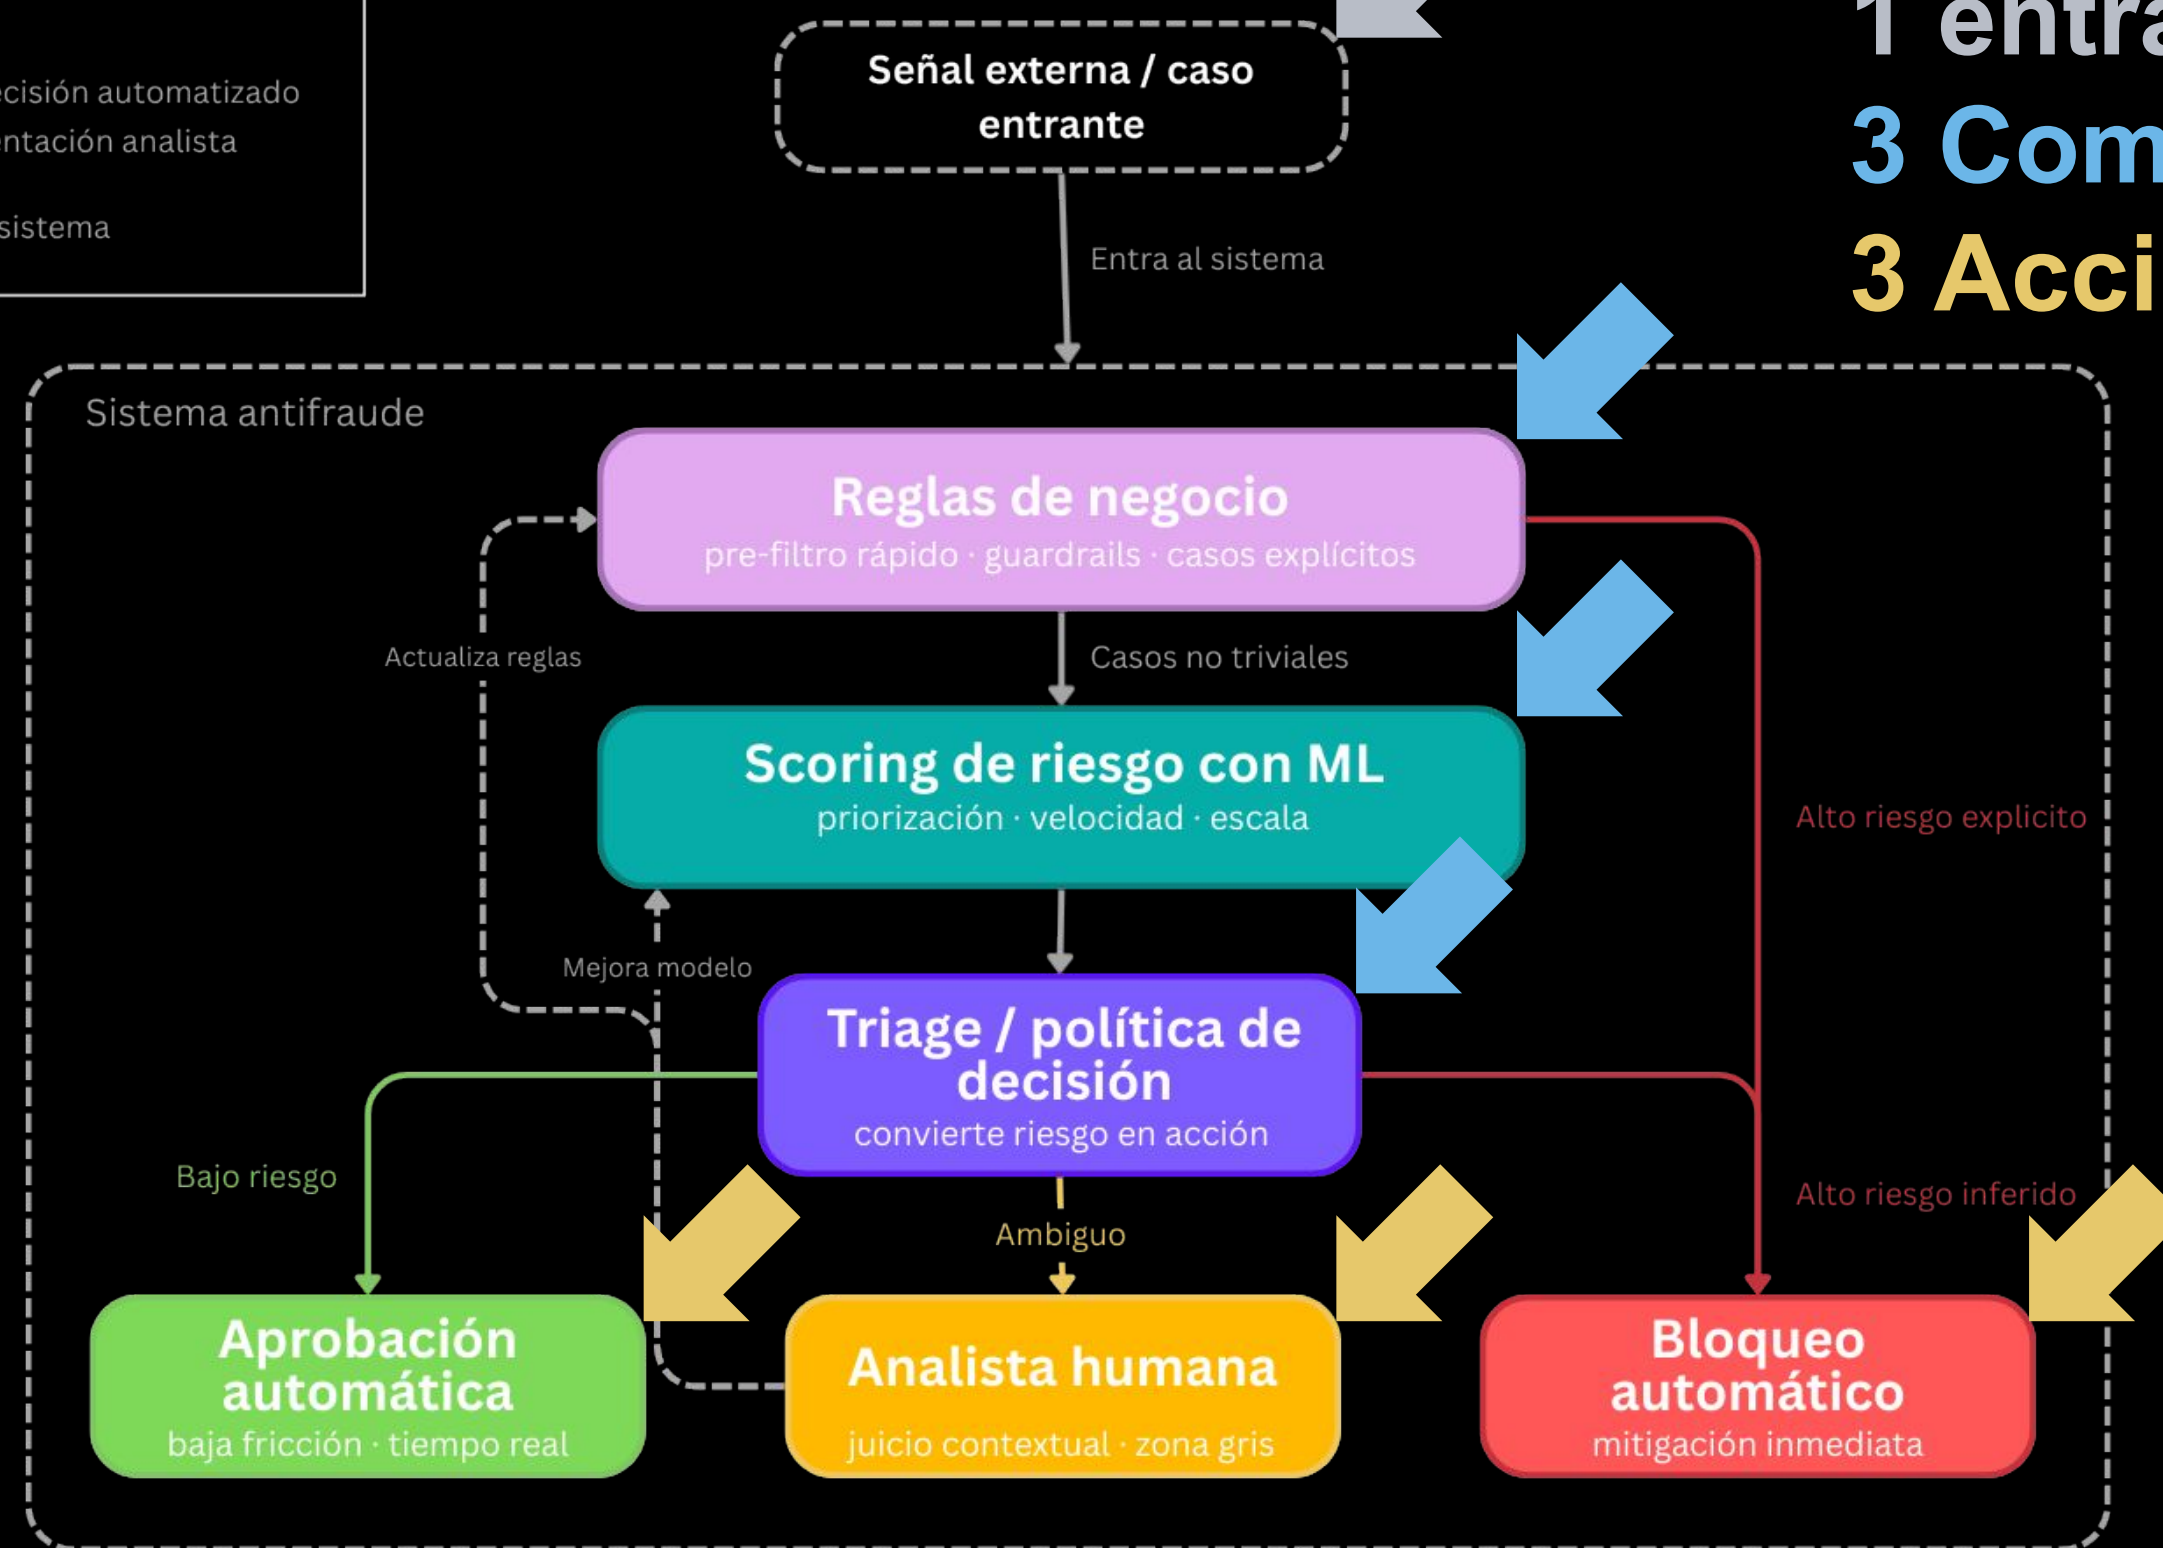
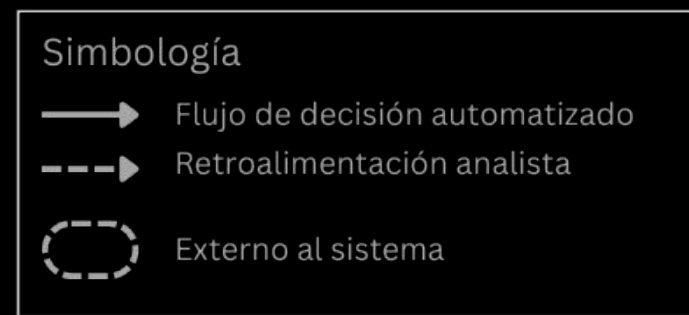


# Arquitectura de referencia del patrón





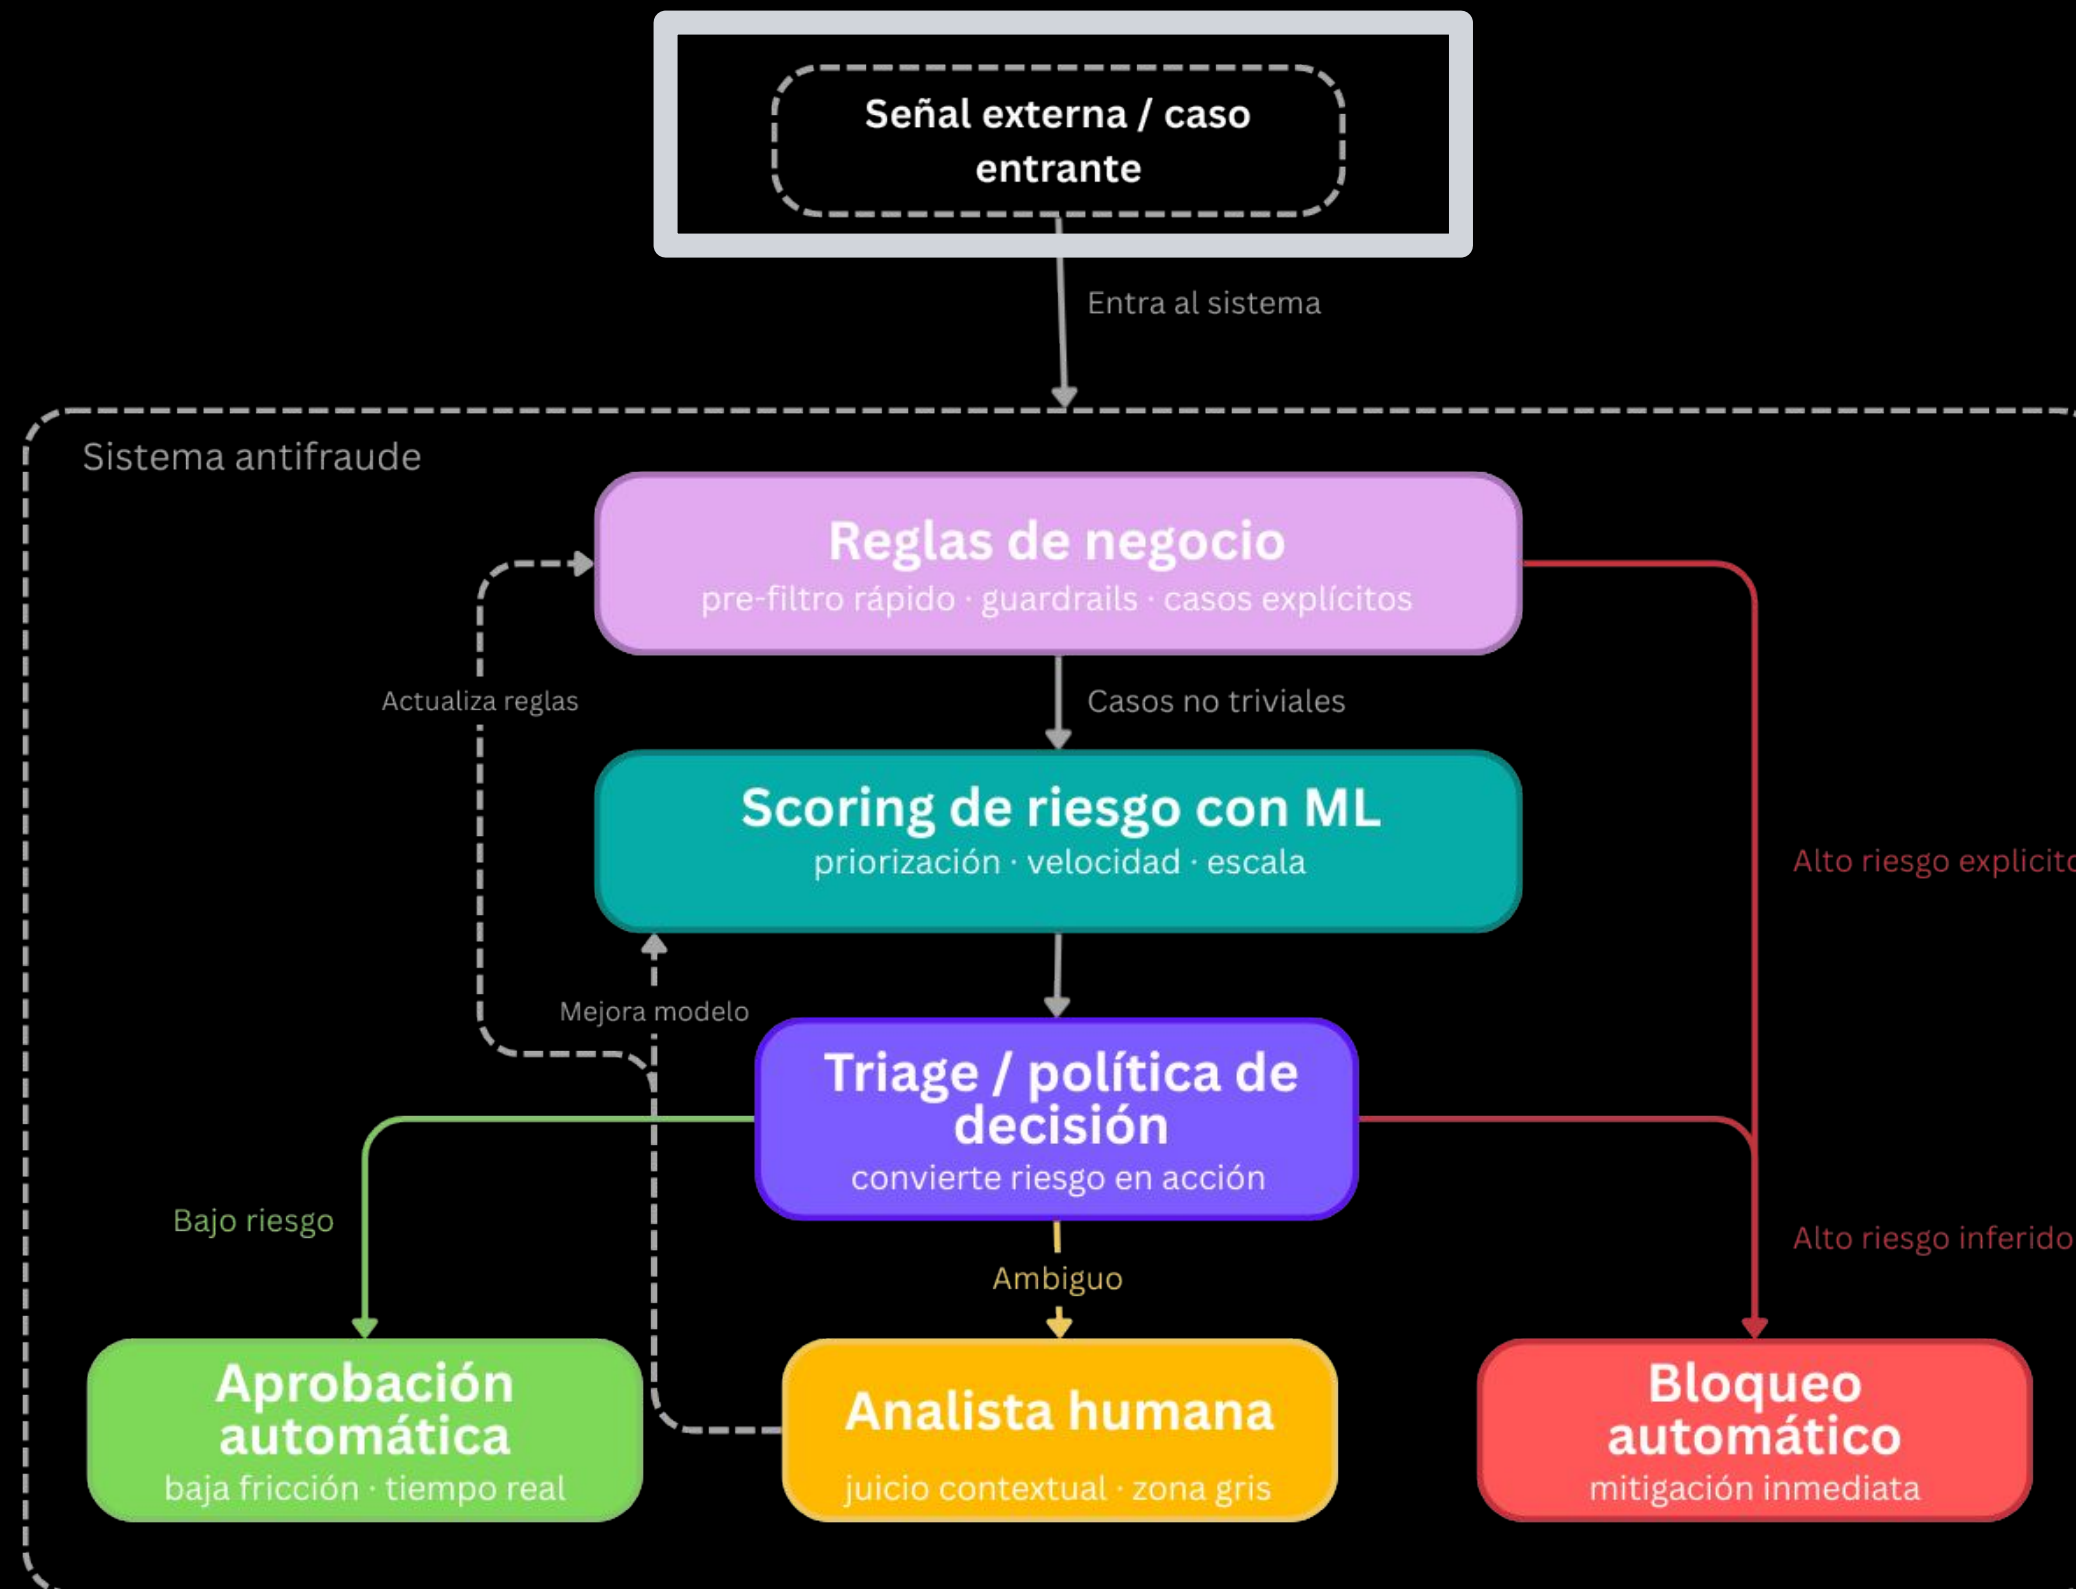
# Arquitectura de referencia del patrón



**1** entrada externa  
**3** Componentes de decisión  
**3** Acciones posibles




# El caso puede nacer dentro o fuera del flujo transaccional



Informe de socio de pago/banco



Esfuerzos automatizados o manuales



Casos judiciales/policiacos (*law enforcement*)

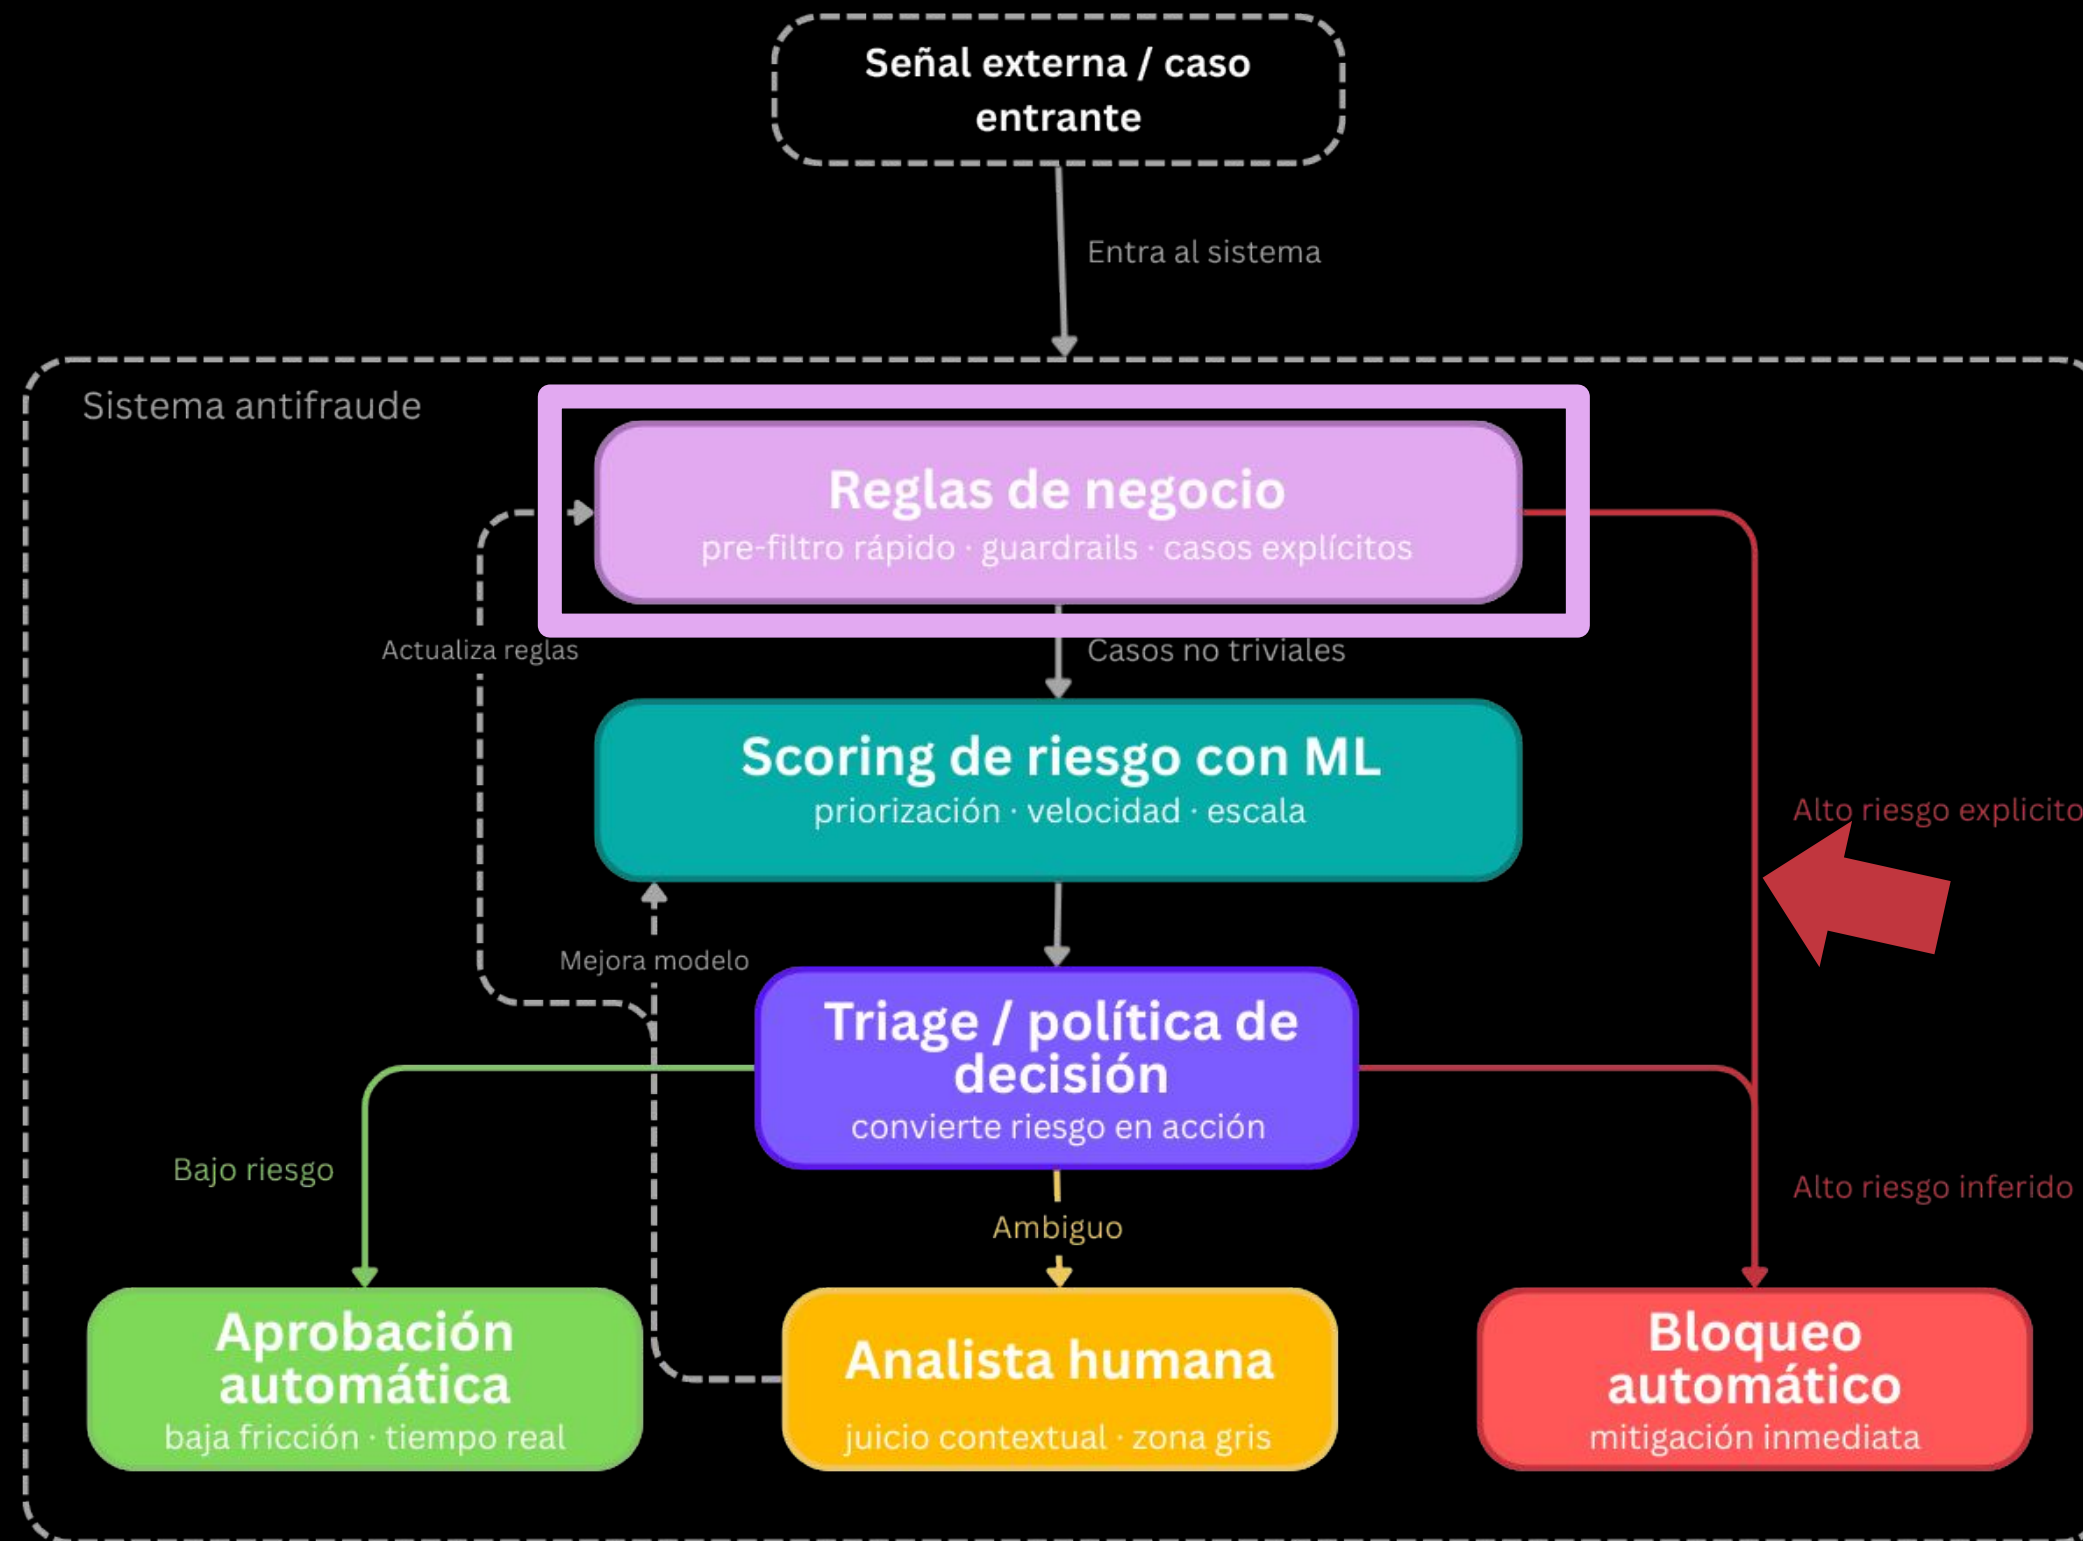


Disputas con clientes



- El sistema recibe señales desde múltiples fuentes
- No todo caso nace de una transacción
- El caso puede originarse por señales internas o externas



# Reglas



- **Qué hace:** filtra casos **explícitos** y auditables
- **Por qué importa:** responde rápido y aplica *guardrails*
- **Cuidado:** si dependes demasiado de reglas, se vuelven rígidas y evadibles

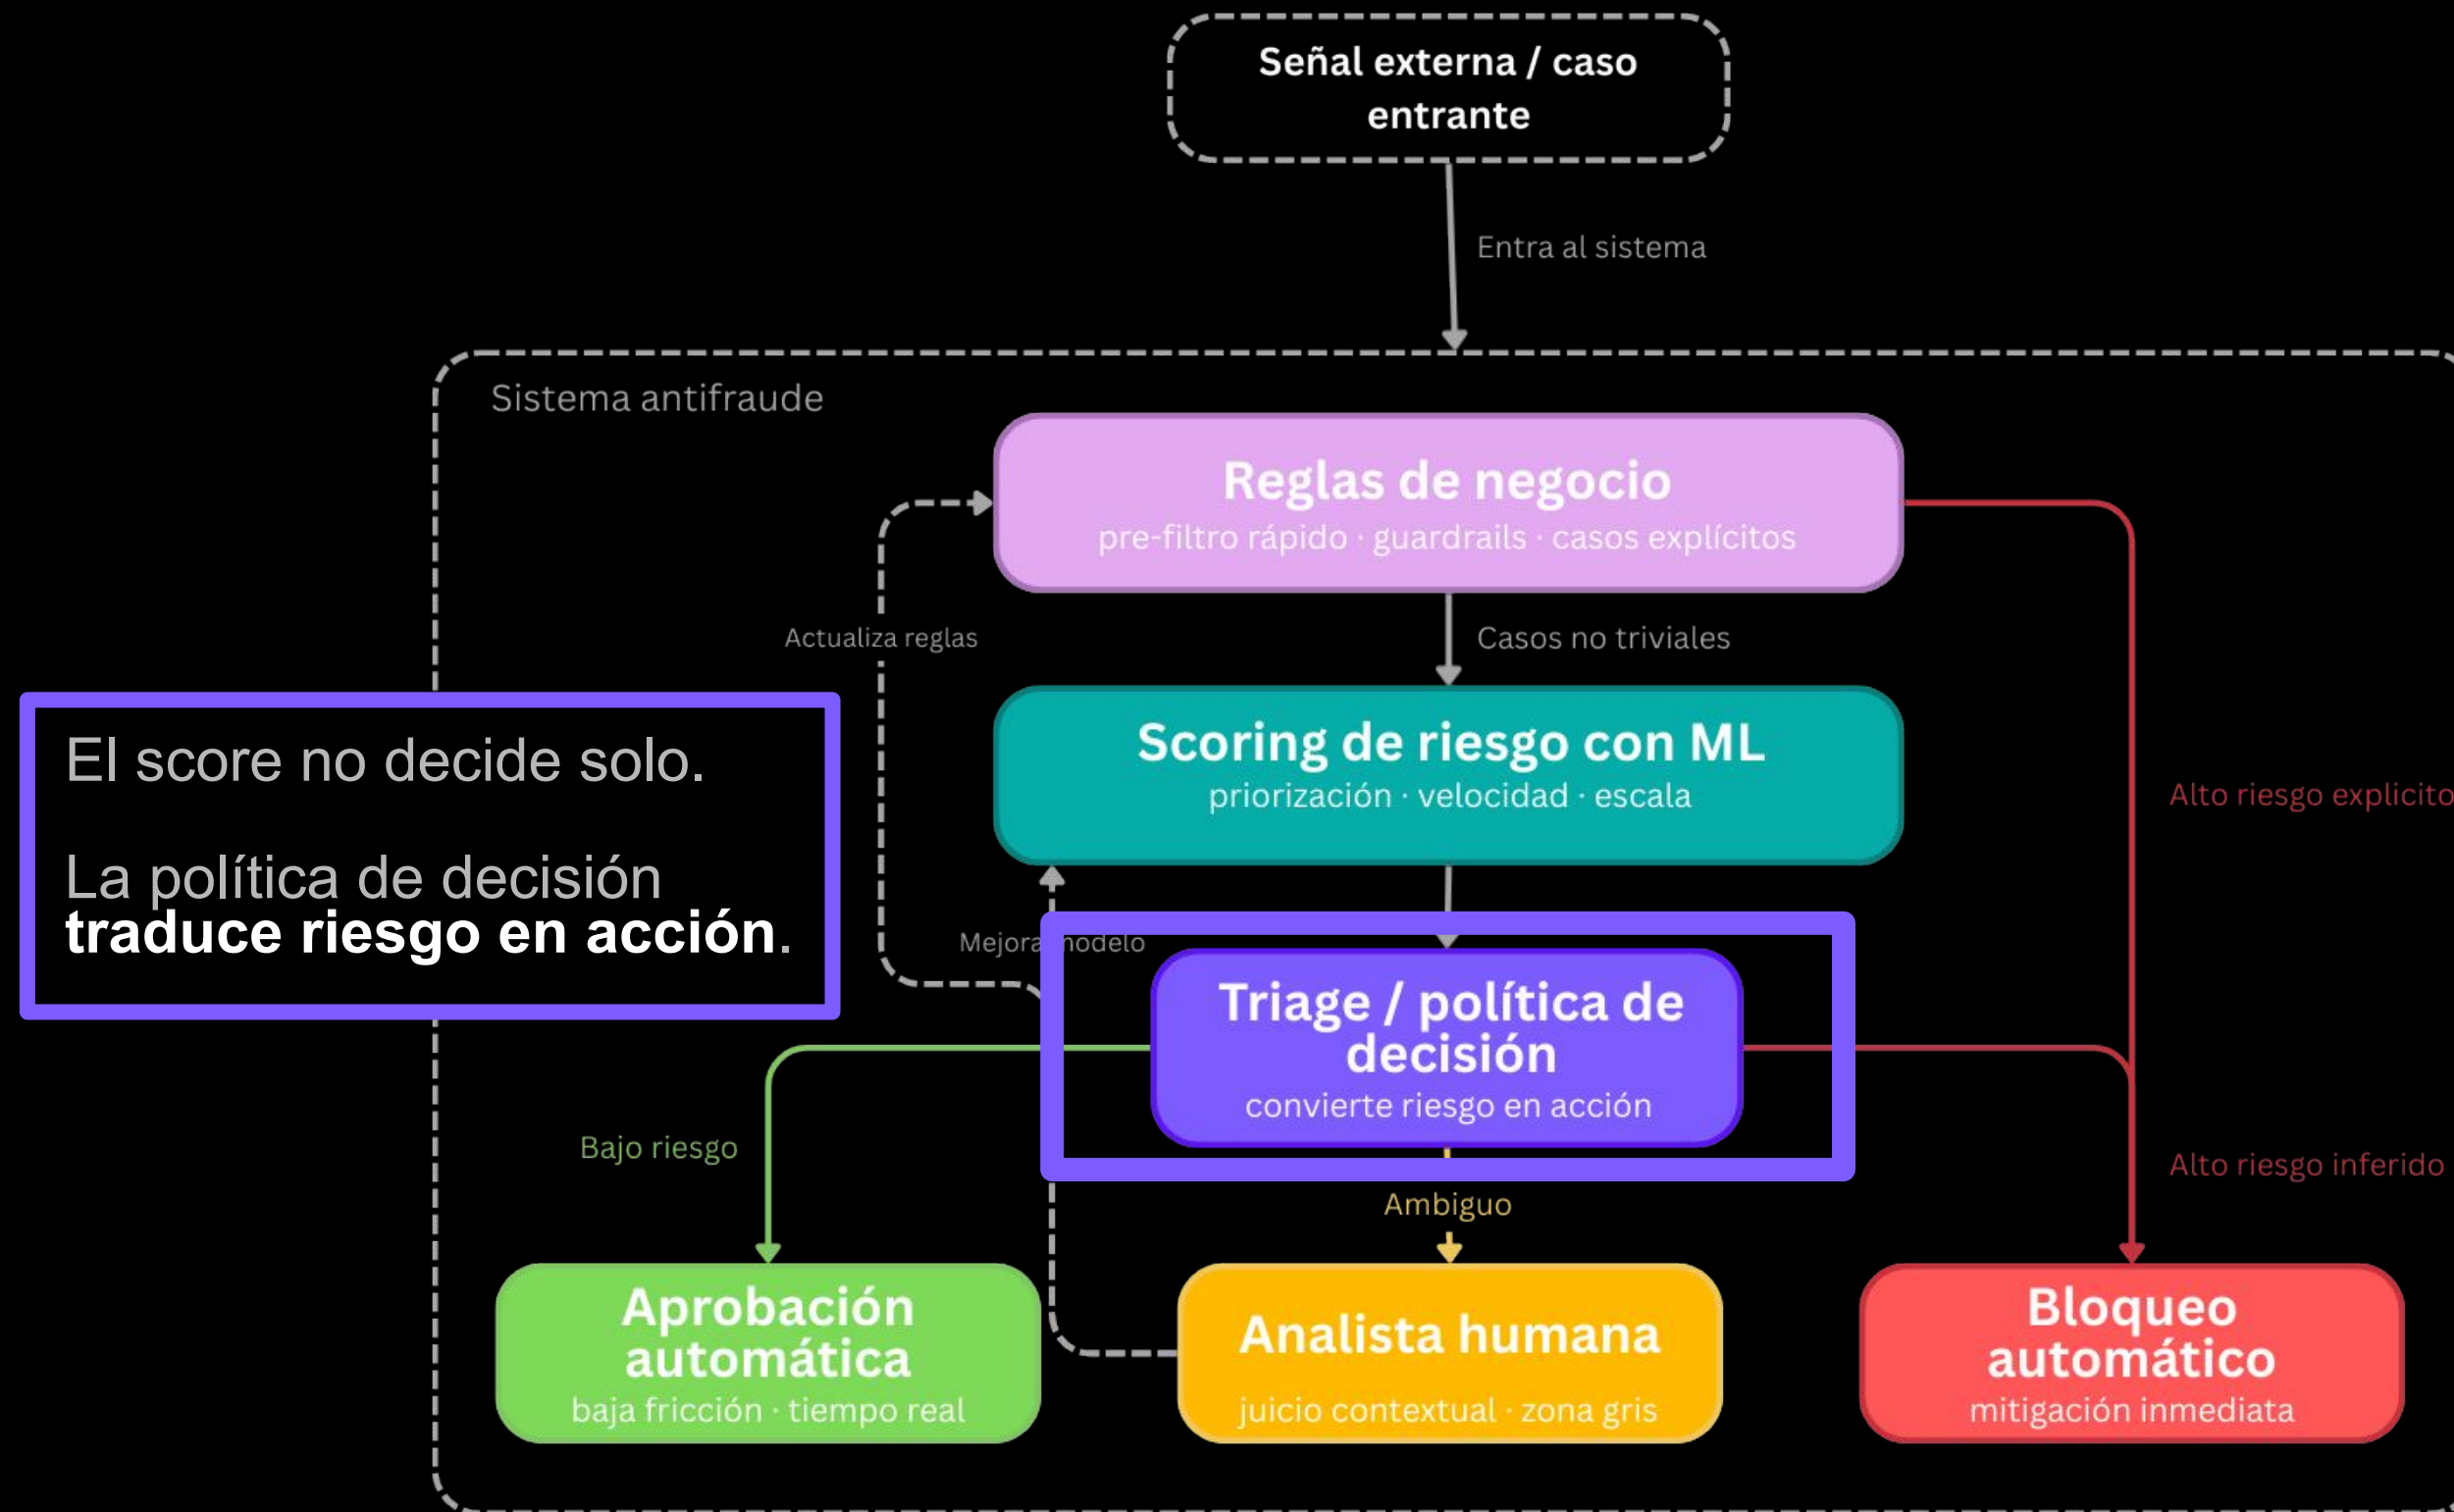


# Scoring con ML



- **Qué hace:** **destila** múltiples señales en un *score* de riesgo
- **Por qué importa:** prioriza a escala
- **Cuidado:** requiere calibración y monitoreo

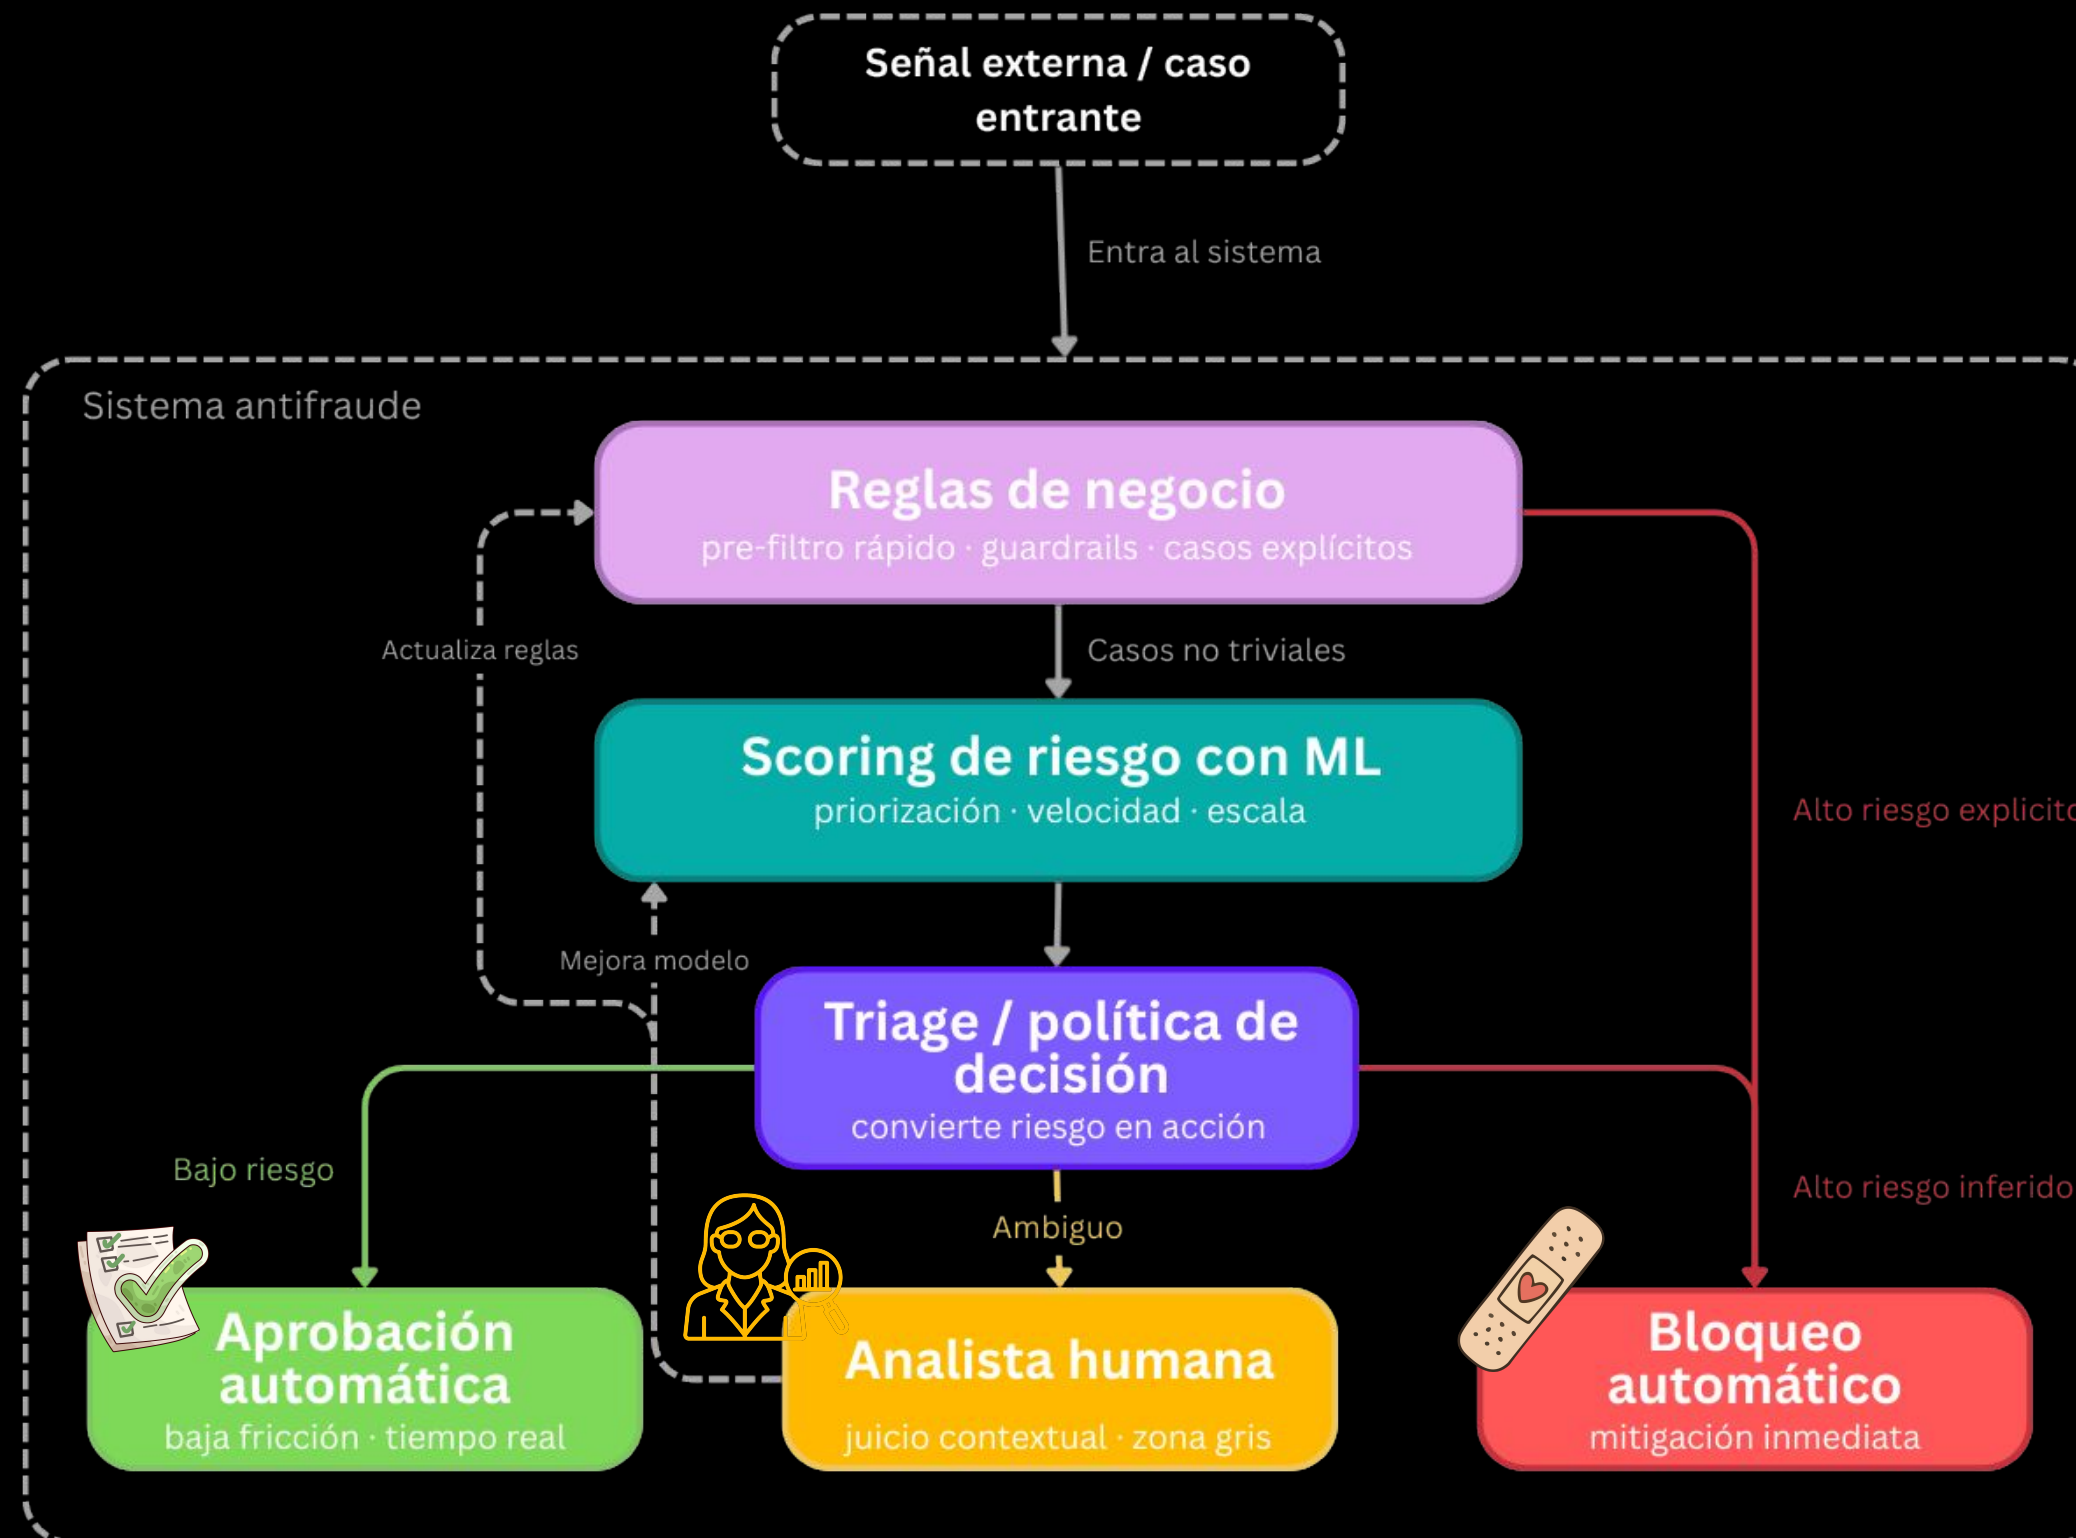
# Triage



El score no decide solo.  
La política de decisión  
**traduce riesgo en acción.**

- **Qué hace:** convierte riesgo en acción
- **Por qué importa:** separa score de decisión operacional
- **Cuidado:** los thresholds y políticas también deben gobernarse


# Acciones



- Se **reduce la fricción** a usuarios legítimos: inmediato
- Casos ambiguos se envían a **revisión humana**: se tarda
- Bloqueo **inmediato**: mitiga el impacto (🕒). Puede ser cualquier medida de **presión/fricción**



# Retroalimentación y mejora continua



- **Analistas** aportan retroalimentación para mejora del sistema
- Nuevas reglas
- Etiquetas revisadas y correcciones para el **sistema ML**


# El ML potencia a las analistas; las analistas mejoran al ML

- El **ML** amplifica la capacidad operativa de las analistas
- Las **analistas** aportan **feedback experto** para mejorar reglas, umbrales y modelos
- La colaboración reduce fricción innecesaria y mejora el aprendizaje del sistema



No es un modelo aislado.

Es un sistema de decisión con **aprendizaje operativo**.



# Del score a la acción y al aprendizaje



# El score no decide solo

- El score **resume riesgo**; la política **define la acción**
- Un buen modelo mal integrado produce malas decisiones





# Las analistas no son respaldo: son parte del sistema

- Resuelven la **zona gris** y los casos novedosos
- Aportan **juicio contextual** donde el modelo duda
- Su tiempo debe reservarse para casos ambiguos, no para revisar todo
- Su trabajo se conecta mediante **feedback estructurado**
- **Crecen con el sistema:** el contacto con ML abre caminos hacia ciencia de datos



**Invertir en su crecimiento técnico  
fortalece el sistema, no solo al equipo**

# Ciclo de mejora continua

- La interfaz debe facilitar **feedback estructurado**, no solo comentarios libres
- Ese *feedback* puede **re-etiquetar casos**, ajustar thresholds y crear nuevas reglas
- Así, la revisión humana mejora tanto el modelo como la política de decisión

Las analistas no sólo resuelven casos;  
**entrenan al sistema**

# Trade-offs que sí importan

- Más revisión humana mejora el juicio, pero aumenta **costo y latencia**
- Más automatización escala mejor, pero puede ocultar **errores sistémicos**
- Mayor complejidad arquitectónica exige más **gobernanza y monitoreo**



**El patrón no elimina estos trade-offs; los hace  
visibles y gobernables**

# Blueprint para llevarse mañana

## Diseñar:

- Define resultados esperados y costos de error
- Diseña bandas de riesgo
- Separa *score* de *policy*

## Operar:

- Crea la zona de revisión humana
- Monitorea *drift*, falsos positivos y tiempos de revisión
- Define SLAs para la cola de revisión humana

## Aprender y gobernar:

- Captura *feedback* estructurado
- Establece gobernanza sobre umbrales, reglas, y acceso a datos

*Diseña, opera,  
aprende y gobierna.*

# Para cerrar





Cierre

***En fraude, automatizarlo todo puede ser tan ingenuo como revisarlo todo a mano.***

***La mayor ventaja está en diseñar sistemas donde el ML escala y las analistas entrenan al sistema.***

# Preguntas





# Referencias



# Referencias

- Amershi, S., Weld, D., Vorvoreanu, M., Fourney, A., Nushi, B., Collisson, P., Suh, J., Iqbal, S., Bennett, P. N., Inkpen, K., Teevan, J., Kikin-Gil, R., & Horvitz, E. (2019). Guidelines for human-AI interaction. In Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. Association for Computing Machinery. <https://doi.org/10.1145/3290605.3300233>
- ★ Bolton, R. J., & Hand, D. J. (2002). *Statistical fraud detection: A review*. Statistical Science, 17(3), 235–255. <https://doi.org/10.1214/ss/1042727940>
- Chen, Y., Zhao, C., Xu, Y., Nie, C., & Zhang, Y. (2025). Deep learning in financial fraud detection: Innovations, challenges, and applications. Data Science and Management. Advance online publication. <https://doi.org/10.1016/j.dsm.2025.08.002>
- Ding, X., Seleznev, N., Kumar, S., Bruss, C. B., & Akoglu, L. (2023). *From detection to action: A human-in-the-loop toolkit for anomaly reasoning and management*. In Proceedings of the Fourth ACM International Conference on AI in Finance (pp. 279–287). Association for Computing Machinery. <https://doi.org/10.1145/3604237.3626872>

# Referencias

- Emergency Nurses Association. (2019). *Sheehy's emergency nursing: principles and practice*. Elsevier Health Sciences.
- Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1995). *Design patterns: elements of reusable object-oriented software*. Pearson Deutschland GmbH.
- Hernandez Aros, L., Bustamante Molano, L. X., Gutierrez-Portela, F., Moreno Hernandez, J. J., & Rodríguez Barrero, M. S. (2024). Financial fraud detection through the application of machine learning techniques: A literature review. *Humanities and Social Sciences Communications*, 11(1), 1–22.  
<https://doi.org/10.1057/s41599-024-03606-0>
- Hilal, W., Gadsden, S. A., & Yawney, J. (2022). *Financial fraud: A review of anomaly detection techniques and recent advances*. *Expert Systems with Applications*, 193, 116429. <https://doi.org/10.1016/j.eswa.2021.116429>
- Kádár, T. (2025). The rise of human-in-the-loop fraud prevention: Why analyst-AI collaboration matters. SEON.  
<https://seon.io/resources/human-in-the-loop-fraud-detection-and-prevention/>

# Referencias


- Kästner, C. (2025). *Machine learning in production: From models to products*. MIT Press. <https://mlip-cmu.github.io/book/>
- Konieczny, B. (2025). *Data engineering design patterns: Recipes for solving the most common data engineering problems*. O'Reilly Media.
- ★ Mosqueira-Rey, E., Hernández-Pereira, E., Alonso-Ríos, D., Bobes-Bascarán, J., & Fernández-Leal, Á. (2023). *Human-in-the-loop machine learning: A state of the art*. *Artificial Intelligence Review*, 56, 3005–3054.  
<https://doi.org/10.1007/s10462-022-10246-w>
- Lakshmanan, V., Robinson, S., & Munn, M. (2020). *Machine learning design patterns*. O'Reilly Media.

# Referencias

- ★ Lewis, G. A., Ozkaya, I., & Xu, X. (2021). Software architecture challenges for ML systems. In 2021 *IEEE International Conference on Software Maintenance and Evolution (ICSME)*. IEEE. <https://doi.org/10.1109/ICSME52107.2021.00071>
- Lunghi, D., Simitsis, A., Caelen, O., & Bontempi, G. (2023). Adversarial learning in real-world fraud detection: Challenges and perspectives. In *Proceedings of the Second ACM Data Economy Workshop* (pp. 27–33). Association for Computing Machinery. <https://doi.org/10.1145/3600046.3600051>
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., ... & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28.
- ★ Andersen, J., & Maalej, W. (2024). Design patterns for machine learning-based systems with humans in the loop. *IEEE Software*, 41(4), 151–159. <https://doi.org/10.1109/MS.2023.3340256>
- Yuan, X., Yu, P., Liu, S., Sun, Z., Zhang, Y., & Xu, J. (2026). An expert-in-the-loop framework for unknown attack detection via open-set recognition. *Journal of Computer Security*. Advance online publication. <https://doi.org/10.1177/0926227X251414058>
- ★ Zelvenskiy, S., Harisinghani, G., Yu, T., Ng, E., & Wei, R. (2022). Project RADAR: Intelligent early fraud detection system with humans in the loop. Uber Blog. <https://www.uber.com/en-CR/blog/project-radar-intelligent-early-fraud-detection/>




# Material de apoyo






# Evaluación y métricas

- Sistema complejo y heterogéneo
- Se debe evaluar según componentes

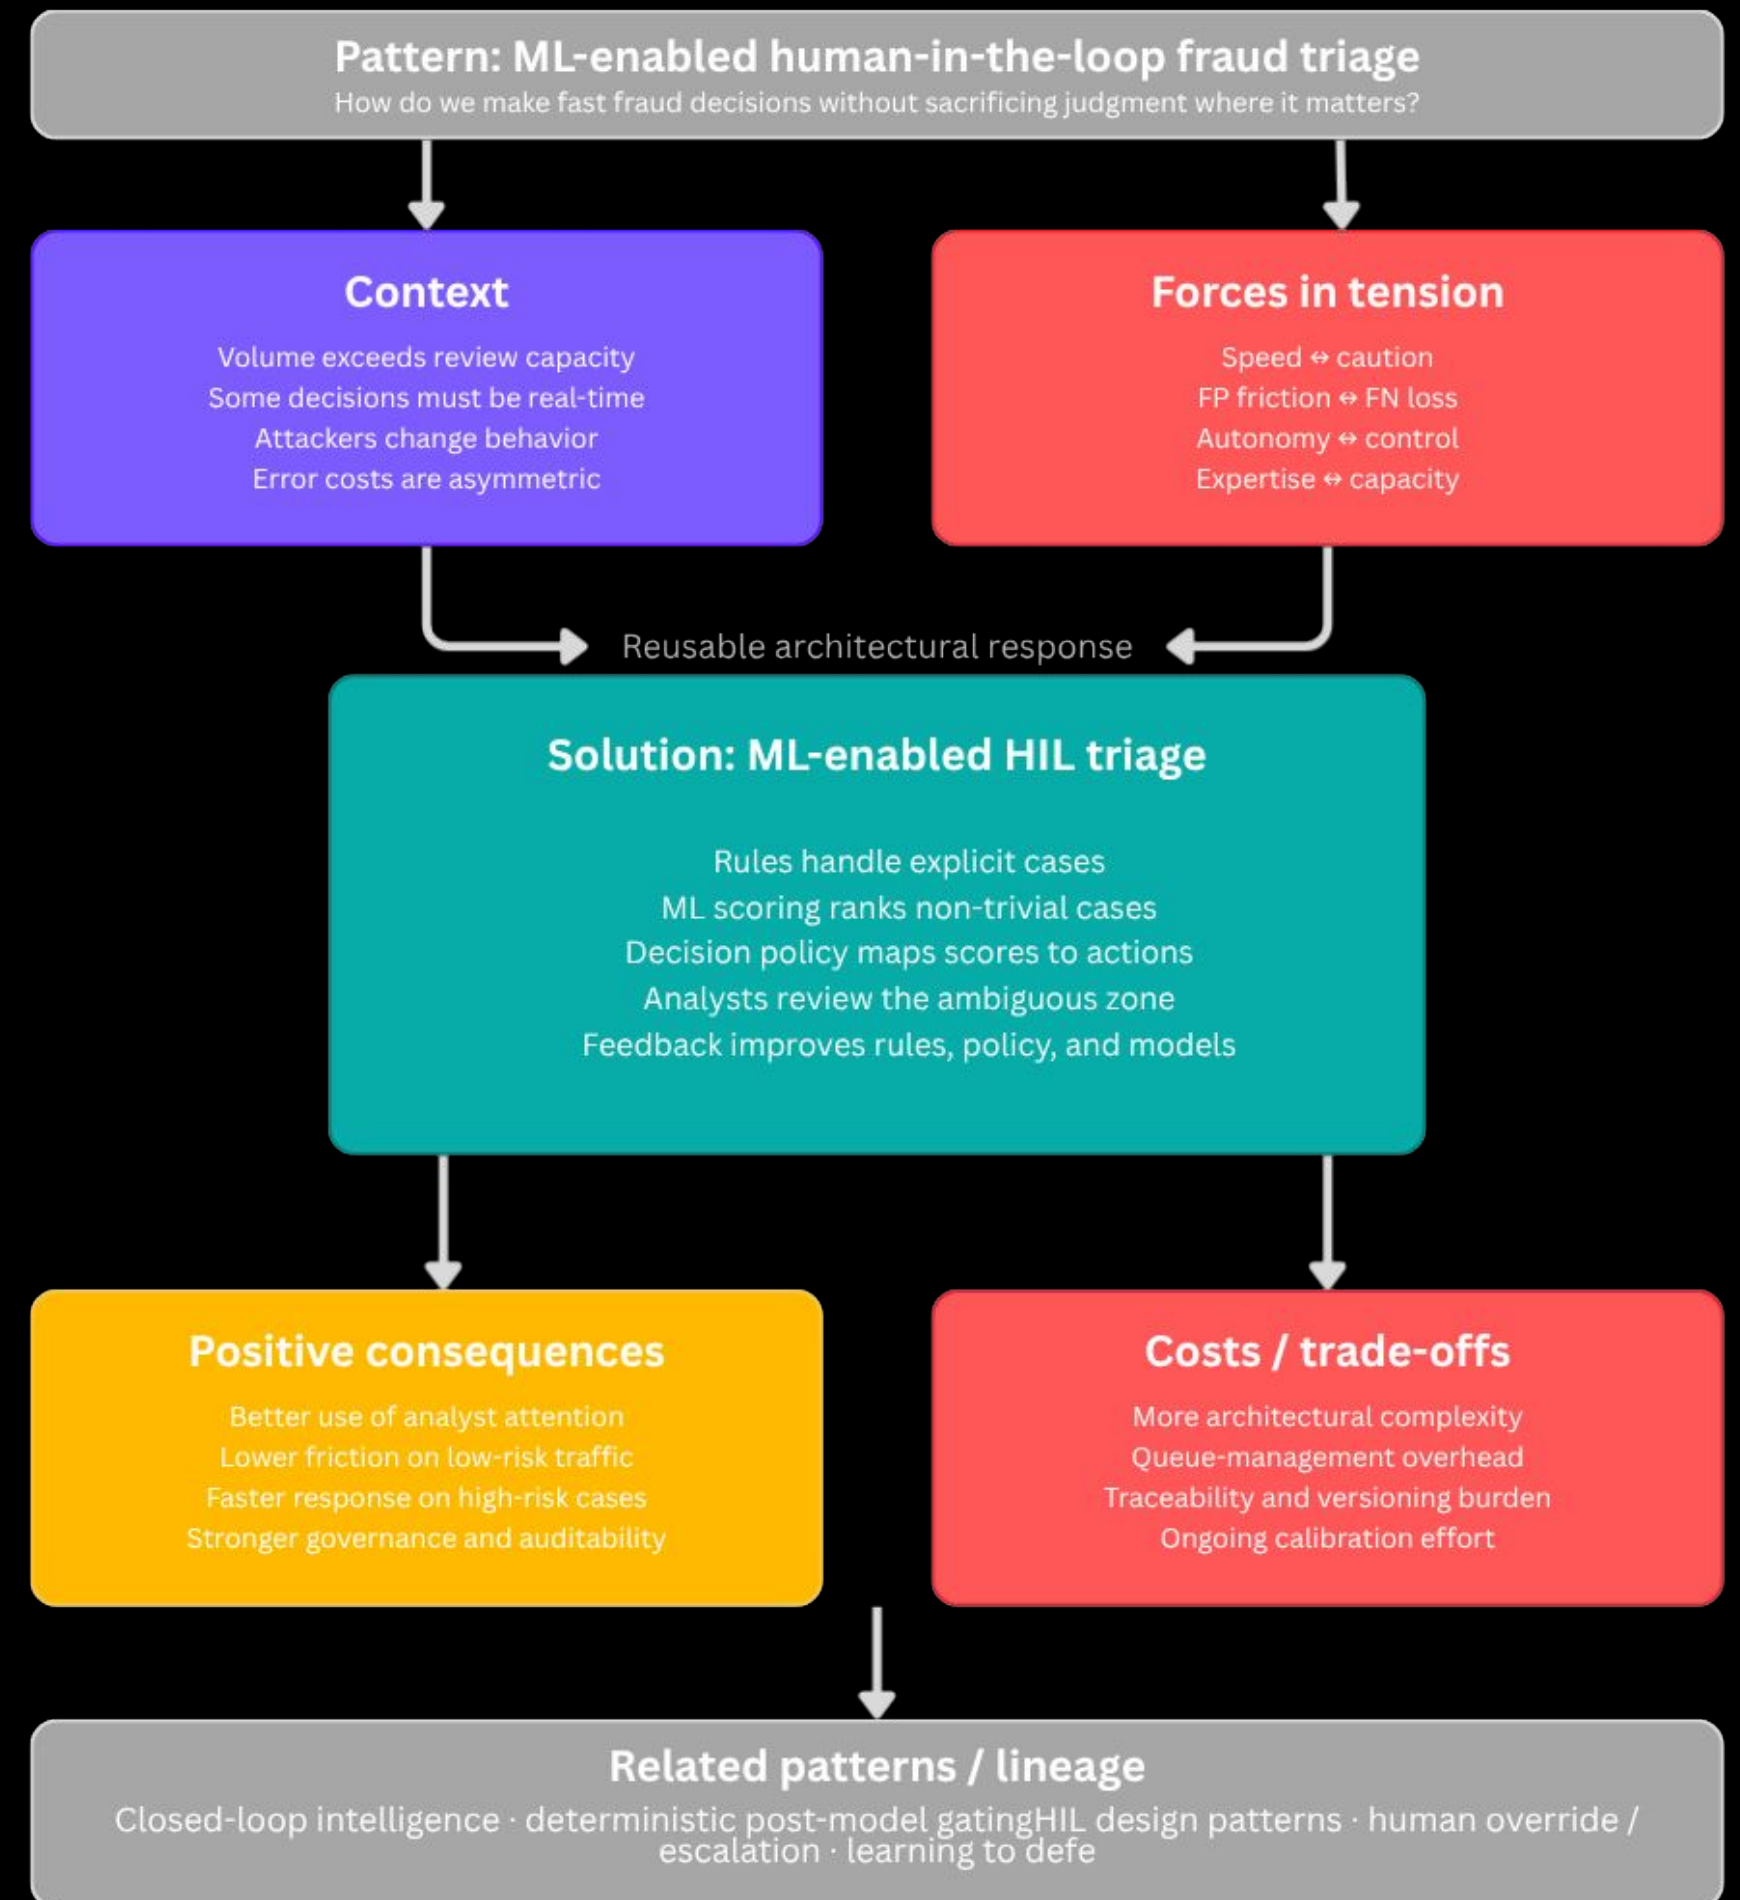


# MLOps





# Pattern framing



# Analyst Workbench (UI)

- Feedback estructurado
- Cola priorizada
- Detalles para analistas

Fraud analyst workbench

12 pending

All bands

Ambiguous

High risk

Escalated

| CASE                                            | BAND      | REASON CODES                 | SLA     |                         |
|-------------------------------------------------|-----------|------------------------------|---------|-------------------------|
| <b>TXN-90281</b><br>\$4,828 · new device · BR   | High      | velocity<br>geo-shift        | 0:12:41 | <button>Review</button> |
| <b>TXN-90277</b><br>\$1,285 · known device · MX | Ambiguous | amount-spike                 | 0:34:18 | <button>Review</button> |
| <b>TXN-90264</b><br>\$788 · returning user · CL | Ambiguous | pattern-break<br>time-of-day | 0:48:02 | <button>Review</button> |
| <b>TXN-90259</b><br>\$2,188 · new account · AR  | Ambiguous | new-acct<br>high-value       | 0:55:30 | <button>Review</button> |
| <b>TXN-90252</b><br>\$348 · known device · CO   | Ambiguous | frequency                    | 1:02:11 | <button>Review</button> |
| <b>TXN-90248</b><br>\$615 · known device · PE   | Ambiguous | merchant-cat                 | 1:14:55 | <button>Review</button> |

**Case detail: TXN-90281**

RISK SCORE

0.87

TOP SIGNALS

Device age

2 hrs

Txn velocity (1h)

6 txns

Geo distance

4,200 km

Account age

14 days

Amount percentile

P98

SLA STATUS

🕒 12 min 41 sec

(SLA: 30 min)

ANALYST DECISION

Approve

Block

Escalate

STRUCTURED FEEDBACK

Reason code...

▼


Confidence...

▼

Escalation path...

▼

# Una serie de 3 charlas



# PyLatam 2026

Están invitad@s!!!



UNIVERSIDAD DE  
COSTA RICA



2026 • Costa Rica  
**PYCON LATAM**



## CALL FOR PAPERS

¿Tienes una idea, proyecto o experiencia que merece ser compartida? Este es el momento de inspirar, enseñar y conectar con la comunidad Python más grande de Latinoamérica.

¡Tu voz importa!  
Registra tu charla en [www.pylatam.org](http://www.pylatam.org)






Preparamos esta presentación con:



Canva



GIMP



Google Slides