




Prevención de fraude:

ML y patrones de diseño

mantén a tus analistas en el loop

Material de la charla

Repositorio de GitHub



https://github.com/jospablo777/fraud_ml_design_pattern

Contacto (LinkedIn)



<https://www.linkedin.com/in/jose-barrantes/>

Contenido

1. Fraude como problema de arquitectura

2. Por qué no basta un solo componente

3. El patron: ML + analistas + reglas

4. Blueprint para aplicarlo mañana

Con esta charla queremos

- Desarrollar un **lenguaje en común**
- Pensar el **fraude como un problema de arquitectura**, no solo de modelos predictivos
- Motivar a **diseñar mejores sistemas** antifraude con *machine learning* (ML) y humanos expertos

Vamos a hablar de

- Prevención de fraude
- **Arquitectura** de software con ML (*ML-enabled software*)
- El **rol de analistas expertas** en la efectividad del sistema

No es una charla sobre algoritmos, sino sobre diseño de sistemas

Imaginen




Imaginen que..

20 casos entran ahora mismo

- No pueden revisarlos todos
- No pueden bloquearlos todos

¿Qué harían?



El sistema ML los clasifica así

- 10 bajo riesgo
- 5 ambiguos
- 5 alto riesgo




Revisar todo manualmente no escala

Cada caso, en promedio tarda **1 hora** analista en ser procesado.

- Inversión: **20 horas** analista
- **Mayor juicio contextual**



20 hrs



El valor de la detección de fraude es una función del tiempo





Cada minuto de demora puede aumentar el costo del fraude

(Hilal, Gadsden & Yawney, 2022)

Automatizar demasiado también sale caro

El sistema de ML clasifica cada caso en menos de **1 milisegundo** (ms).

- Inversión: **<1 minuto**
- **Rápido**, sí
- Pero **más fricción** y dejamos pasar más **patrones novedosos**




La alternativa: combinar ML + analistas

Híbrido: automatizar lo claro y elevar lo ambiguo

- Reducción de 20 a 5 horas de revisión humana
- De **inmediato** accionamos lo crítico
- Lo mejor de ambos mundos

<1 min

Bajo riesgo



Dejar pasar automáticamente

5 hrs


Ambiguos



Enviar a revisión humana

<1 min

Alto riesgo



Retener automáticamente

¿Qué gana la organización con un diseño híbrido?

- **Menos fricción** para usuarios legítimos
- **Mejor uso** del talento experto
- **Menor costo** por demora

Bajo riesgo



Ambiguos



Alto riesgo



Si bloqueas de más, pierdes clientes.



Si bloqueas de menos, pierdes dinero.



Si revisas todo manualmente, no escalas.



Fraude




¿Por qué el fraude es especialmente difícil?

- Los atacantes se adaptan
- El fraude es raro y las etiquetas imperfectas
- Hay que decidir en tiempo real
- El comportamiento cambia con el tiempo
- Además: explicabilidad y cumplimiento

(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022; Chen et al., 2025)

El fraude es adversarial: el atacante se adapta




Fraude **no es un problema estático**. Cuando un detector funciona, **los atacantes cambian su estrategia**. Por eso no basta con entrenar un modelo “bueno” una vez

(Bolton & Hand, 2002; Lunghi et al., 2023)

El fraude es raro y las etiquetas son imperfectas


- La mayoría de los casos son legítimos. Eso hace que el problema esté fuertemente **desbalanceado**.
- Muchas veces no hay *labels* perfectos o suficientes para entrenar.



(Hilal, Gadsden & Yawney, 2022; Chen et al., 2025)

Hay que decidir rápido, pero los errores cuestan distinto

- No todos los errores cuestan lo mismo.
- Un falso negativo **deja pasar** fraude real.
- Un falso positivo mete **fricción**, costo operativo y mala experiencia.
- Además, **no hay tiempo infinito** para investigar.



(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022)


No basta con precisión: explicabilidad, privacidad y cumplimiento

- Explicar decisiones
- Respetar regulaciones de privacidad
- Operar bajo controles de gobernanza y auditoría




(Hernandez Aros et al., 2024; Chen et al., 2025)

El fraude no es sólo un problema de predicción; es un problema de **decisión operativa bajo incertidumbre**



Ni reglas, ni ML, ni revisión humana bastan por sí solos

El fraude es un problema de sistema, no de una pieza aislada



Reglas

Aportan:

- Respuesta inmediata
- Simplicidad
- Auditabilidad

Pero no bastan:

- Son rígidas
- Se vuelven fáciles de evadir
- Requieren mantenimiento continuo



(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022;
Ding et al., 2023)


Machine learning (ML)

Aporta:

- Escala
- Velocidad
- Consistencia

Pero no basta:

- Puede ser difícil de explicar
- Es sensible al *drift* y a tácticas nuevas
- Puede aumentar fricción sobre usuarios legítimos



(Hilal, Gadsden & Yawney, 2022; Lunghi et al., 2023;
Chen et al., 2025)

Analistas

Aportan:

- Juicio contextual
- Detección de patrones novedosos
- Mejor manejo de la zona gris

Pero no bastan:

- No escala
- Es costoso
- Introducen demoras operativas




(Amershi et al., 2019; Zelvenskiy et al., 2022; Ding et al., 2023; Mosqueira-Rey et al., 2023)

No se trata de qué componente elegir, sino de cómo hacerlos **trabajar juntos**.




Un sistema con ML no es solo un modelo

- **ML:** scoring, predicción
- **Software tradicional:** APIs, reglas, integración, gestión de casos
- **Infraestructura/plataforma:** monitoreo, gobernanza, despliegue, automatización



(Sculley et al., 2015; Lewis, Ozkaya & Xu, 2021; Kästner 2025)

En producción, el modelo vive rodeado de infraestructura, operaciones, software convencional, y **expertos humanos**



(Sculley et al., 2015; Lewis, Ozkaya & Xu, 2021; Kästner 2025)

Planeamiento y arquitectura

Los componentes se deben de planear en conjunto desde la fase de arquitectura, no en secuencia ni de manera aislada.




Figura construida a partir de Lewis, Ozkaya & Xu (2021), de Andersen, & Maalej (2024), y de Kästner (2025)

El humano como componente arquitectónico

- **Casos ambiguos:** casos inciertos son delegados para revisión humana (*Learning to Defer*; L2D)
- **Aprendizaje continuo:** el *feedback* humano mejora el sistema

El *HIL* es una decisión arquitectónica

(Zelvenskiy et al., 2022; Mosqueira-Rey et al., 2023;
Andersen & Maalej, 2024; Alves et al., 2025)

La sinergia entre ML y expertas no es opcional

ML:

- Escala
- Priorización
- Velocidad

→ Prioriza qué mirar

Analistas:

- Contexto
- Validación
- Juicio

→ Corrigen y enseñan

Sistema:

- Calibrado
- Aprende continuamente

→ Mejora el siguiente ciclo

El *HIL* es una estrategia de desempeño y adaptación

(Chai et al., 2020; Mosqueira-Rey et al., 2023; Ding et al., 2023; Andersen & Maalej, 2024; Yuan et al., 2026)

Patrones de diseño



Patrones de diseño

Una solución reusable a un problema común dentro de un contexto específico

O una plantilla adaptable para resolver un problema recurrente




(Lakshmanan et al., 2020; Konieczny, 2025)


Patrones de diseño

Recursos


- Reciente interés de expandirlos a la “ciencia de datos”




(Gamma et al., 1995)



(Lakshmanan et al., 2020)



(Konieczny, 2025)



Patrones de diseño: características

- Adaptables
- Reusables
- Responden a un problema específico
 - Por ejemplo, el fraude ocurre en muchas compañías y productos
- Nos ahorran tiempo
- Son generales: no proveen detalles de implementación



(Lakshmanan et al., 2020; Konieczny, 2025)

Nuestro patrón de diseño

ML-enabled Human-in-the-loop (HIL) Triage



Patrón: *ML-enabled HIL Triage*

- **Problema:** ¿Cómo tomar decisiones antifraude **rápidas** sin sacrificar **juicio** en los casos que más importan?
- **Contexto:** Sistemas donde el volumen supera la capacidad humana, pero automatizar todo introduce puntos ciegos.



ML-enabled Human-in-the-loop Triage

- **Solución:**

Clasificar casos por bandas de riesgo y asociarla a una política de acción:

- **bajo riesgo** va a automatizar favorablemente
- **alto riesgo** va a mitigar automáticamente
- **zona gris** va a revisión humana



ML-enabled Human-in-the-loop Triage

- **Consecuencias:**

- Mejor uso del talento experto
- Menor fricción innecesaria
- Mayor capacidad de adaptación
- Mayor complejidad operacional

- **Por qué funciona?**

Alinea cada tipo de decisión con el recurso más adecuado:


- reglas para condiciones explícitas
- *ML* para priorización a escala
- analistas para incertidumbre contextual



Anatomía del sistema





Arquitectura de referencia del patrón




El patrón transforma señales en acción

Arquitectura de referencia del patrón



1 entrada externa
3 Componentes de decisión
3 Acciones posibles


El caso puede nacer dentro o fuera del flujo transaccional



Informe de socio de pago/banco



Esfuerzos automatizados o manuales



Casos judiciales/policiacos (*law enforcement*)




Disputas con clientes





- El sistema recibe señales desde múltiples fuentes
- No todo caso nace de una transacción
- El caso puede originarse por señales internas o externas

Reglas




- **Qué hace:** filtra casos **explícitos** y auditables
- **Por qué importa:** responde rápido y aplica *guardrails*
- **Cuidado:** si dependes demasiado de reglas, se vuelven rígidas y evadibles

Scoring con ML




- **Qué hace:** **destila** múltiples señales en un *score* de riesgo
- **Por qué importa:** prioriza a escala
- **Cuidado:** requiere calibración y monitoreo

Triage




- **Qué hace:** convierte riesgo en acción
- **Por qué importa:** separa score de decisión operacional
- **Cuidado:** los thresholds y políticas también deben gobernarse

Acciones



- Se **reduce la fricción** a usuarios legítimos: inmediato
- Casos ambiguos se envían a **revisión humana**: se tarda
- Bloqueo **inmediato**: mitiga el impacto (🕒). Puede ser cualquier medida de **presión/fricción**

Retroalimentación y mejora continua




- **Analistas** aportan retroalimentación para mejora del sistema
- Nuevas reglas
- Etiquetas revisadas y correcciones para el **sistema ML**

El ML potencia a las analistas; las analistas mejoran al ML

- El **ML** amplifica la capacidad operativa de las analistas
- Las **analistas** aportan **feedback experto** para mejorar reglas, umbrales y modelos
- La colaboración reduce fricción innecesaria y mejora el aprendizaje del sistema



Es un sistema de decisión con
aprendizaje operativo.



Score, acción, y aprendizaje



El score no decide solo

- El score **resume riesgo**; la política **define la acción**
- Un buen modelo mal integrado produce malas decisiones



Las **analistas** no son respaldo: son parte del sistema

- Aportan **juicio contextual**
- **Su tiempo es valioso**
- **Crece con el sistema:** el contacto con ML abre caminos hacia ciencia de datos

**Invertir en su crecimiento técnico
fortalece el sistema y al equipo**



Ciclo de mejora continua

- La interfaz debe facilitar **feedback estructurado**, no solo comentarios libres
- Ese *feedback* puede **re Etiquetar casos**, ajustar umbrales y crear nuevas reglas
- Así, la revisión humana mejora tanto el modelo como la política de decisión

Las analistas resuelven casos y
entrenan al sistema

Trade-offs

- Más revisión humana mejora el juicio, pero aumenta **costo y latencia**
- Más automatización escala mejor, pero puede ocultar **errores sistémicos**
- Mayor complejidad arquitectónica exige más **gobernanza y monitoreo**



**El patrón no elimina estos trade-offs; los hace
visibles y gobernables**

Blueprint para llevarse mañana

Diseñar:

- Define resultados esperados y costos de error
- Diseña bandas de riesgo
- Separa *score* de *policy*

Operar:

- Crea la zona de revisión humana
- Monitorea *drift*, falsos positivos y tiempos de revisión
- Define SLAs para la cola de revisión humana

Aprender y gobernar:

- Captura *feedback* estructurado
- Establece gobernanza sobre umbrales, reglas, y acceso a datos

*Diseña, opera,
aprende, y gobierna.*

Para cerrar



Cierre

En fraude, automatizarlo todo puede ser tan ingenuo como revisarlo todo a mano.

La mayor ventaja está en diseñar sistemas donde el ML escala y las analistas guían al sistema.

Preguntas



Material de la charla

Repositorio de GitHub



https://github.com/jospablo777/fraud_ml_design_pattern

Contacto (LinkedIn)



<https://www.linkedin.com/in/jose-barrantes/>

Referencias



Referencias

- ★Alves, J. V., Leitão, D., Jesus, S., Sampaio, M. O. P., Liébana, J., Saleiro, P., Figueiredo, M. A. T., & Bizarro, P. (2025). A benchmarking framework and dataset for learning to defer in human-AI decision-making. *Scientific Data*, 12, 506. <https://doi.org/10.1038/s41597-025-04664-y>
- Amershi, S., Weld, D., Vorvoreanu, M., Fournery, A., Nushi, B., Collisson, P., Suh, J., Iqbal, S., Bennett, P. N., Inkpen, K., Teevan, J., Kikin-Gil, R., & Horvitz, E. (2019). Guidelines for human-AI interaction. In Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. Association for Computing Machinery. <https://doi.org/10.1145/3290605.3300233>
- ★Bolton, R. J., & Hand, D. J. (2002). *Statistical fraud detection: A review*. Statistical Science, 17(3), 235–255. <https://doi.org/10.1214/ss/1042727940>
- Chen, Y., Zhao, C., Xu, Y., Nie, C., & Zhang, Y. (2025). Deep learning in financial fraud detection: Innovations, challenges, and applications. Data Science and Management. Advance online publication. <https://doi.org/10.1016/j.dsm.2025.08.002>
- Ding, X., Seleznev, N., Kumar, S., Bruss, C. B., & Akoglu, L. (2023). *From detection to action: A human-in-the-loop toolkit for anomaly reasoning and management*. In Proceedings of the Fourth ACM International Conference on AI in Finance (pp. 279–287). Association for Computing Machinery. <https://doi.org/10.1145/3604237.3626872>

Referencias

- Emergency Nurses Association. (2019). *Sheehy's emergency nursing: principles and practice*. Elsevier Health Sciences.
- Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1995). *Design patterns: elements of reusable object-oriented software*. Pearson Deutschland GmbH.
- Hernandez Aros, L., Bustamante Molano, L. X., Gutierrez-Portela, F., Moreno Hernandez, J. J., & Rodríguez Barrero, M. S. (2024). Financial fraud detection through the application of machine learning techniques: A literature review. *Humanities and Social Sciences Communications*, 11(1), 1–22.
<https://doi.org/10.1057/s41599-024-03606-0>
- Hilal, W., Gadsden, S. A., & Yawney, J. (2022). *Financial fraud: A review of anomaly detection techniques and recent advances*. *Expert Systems with Applications*, 193, 116429. <https://doi.org/10.1016/j.eswa.2021.116429>
- Kádár, T. (2025). The rise of human-in-the-loop fraud prevention: Why analyst-AI collaboration matters. SEON.
<https://seon.io/resources/human-in-the-loop-fraud-detection-and-prevention/>


Referencias

- Kästner, C. (2025). *Machine learning in production: From models to products*. MIT Press. <https://mlip-cmu.github.io/book/>
- Konieczny, B. (2025). *Data engineering design patterns: Recipes for solving the most common data engineering problems*. O'Reilly Media.
- ★ Mosqueira-Rey, E., Hernández-Pereira, E., Alonso-Ríos, D., Bobes-Bascarán, J., & Fernández-Leal, Á. (2023). *Human-in-the-loop machine learning: A state of the art*. *Artificial Intelligence Review*, 56, 3005–3054.
<https://doi.org/10.1007/s10462-022-10246-w>
- Lakshmanan, V., Robinson, S., & Munn, M. (2020). *Machine learning design patterns*. O'Reilly Media.

Referencias


- ★ Lewis, G. A., Ozkaya, I., & Xu, X. (2021). Software architecture challenges for ML systems. In 2021 *IEEE International Conference on Software Maintenance and Evolution (ICSME)*. IEEE. <https://doi.org/10.1109/ICSME52107.2021.00071>
- Lunghi, D., Simitsis, A., Caelen, O., & Bontempi, G. (2023). Adversarial learning in real-world fraud detection: Challenges and perspectives. In *Proceedings of the Second ACM Data Economy Workshop* (pp. 27–33). Association for Computing Machinery. <https://doi.org/10.1145/3600046.3600051>
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., ... & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28.
- ★ Andersen, J., & Maalej, W. (2024). Design patterns for machine learning-based systems with humans in the loop. *IEEE Software*, 41(4), 151–159. <https://doi.org/10.1109/MS.2023.3340256>
- Yuan, X., Yu, P., Liu, S., Sun, Z., Zhang, Y., & Xu, J. (2026). An expert-in-the-loop framework for unknown attack detection via open-set recognition. *Journal of Computer Security*. Advance online publication. <https://doi.org/10.1177/0926227X251414058>
- ★ Zelvenskiy, S., Harisinghani, G., Yu, T., Ng, E., & Wei, R. (2022). Project RADAR: Intelligent early fraud detection system with humans in the loop. Uber Blog. <https://www.uber.com/en-CR/blog/project-radar-intelligent-early-fraud-detection/>

Material de apoyo




Evaluación y métricas


- Sistema complejo y heterogéneo
- Se debe evaluar según componentes



MLOps



Pattern framing



Analyst Workbench (UI)

- Feedback estructurado
- Cola priorizada
- Detalles para analistas

Fraud analyst workbench

12 pending

All bands

Ambiguous

High risk

Escalated

CASE	BAND	REASON CODES	SLA	
TXN-90281 \$4,828 · new device · BR	High	velocity geo-shift	0:12:41	Review
TXN-90277 \$1,285 · known device · MX	Ambiguous	amount-spike	0:34:18	Review
TXN-90264 \$788 · returning user · CL	Ambiguous	pattern-break time-of-day	0:48:02	Review
TXN-90259 \$2,188 · new account · AR	Ambiguous	new-acct high-value	0:55:30	Review
TXN-90252 \$348 · known device · CO	Ambiguous	frequency	1:02:11	Review
TXN-90248 \$615 · known device · PE	Ambiguous	merchant-cat	1:14:55	Review

Case detail: TXN-90281

RISK SCORE

0.87

TOP SIGNALS

Device age

2 hrs

Txn velocity (1h)

6 txns

Geo distance

4,200 km

Account age

14 days

Amount percentile

P98

SLA STATUS

🕒 12 min 41 sec

(SLA: 30 min)

ANALYST DECISION

Approve

Block

Escalate

STRUCTURED FEEDBACK

Reason code...

▼


Confidence...

▼

Escalation path...

▼

Una serie de 3 charlas



PyLatam 2026

Están invitad@s!!!



The poster is for the PyLatam 2026 conference, held in Costa Rica. It features a grid background and logos for the Universidad de Costa Rica, PYCON LATAM, and SÓLVO. The main title 'CALL FOR PAPERS' is in large blue letters. Below it, a paragraph in Spanish invites people to share their ideas, projects, or experiences. A call to action asks if their voice matters and provides the website www.pylatam.org for registration. The bottom of the poster includes a horizontal bar with a color gradient and social media icons for Facebook, Instagram, X, and LinkedIn, all labeled 'PyLatam'.

UNIVERSIDAD DE COSTA RICA 2026 • Costa Rica PYCON LATAM SÓLVO

CALL FOR PAPERS

¿Tienes una idea, proyecto o experiencia que merece ser compartida? Este es el momento de inspirar, enseñar y conectar con la comunidad Python más grande de Latinoamérica.


¡Tu voz importa!
Registra tu charla en www.pylatam.org

PyLatam pylatam PyLatam PyLatam

Preparamos esta presentación con:



Canva



GIMP



Google Slides