




Prevención de fraude: ML y patrones de diseño mantén a tus analistas en el loop

Material de la charla

Repositorio de GitHub



<https://www.linkedin.com/in/jose-barrantes/>

Contacto (LinkedIn)



<https://www.linkedin.com/in/jose-barrantes/>

Contenido

1. Fraude como problema de arquitectura

2. Por qué no basta un solo componente

3. El patron: ML + analistas + reglas

4. Blueprint para aplicarlo manana

Con esta charla queremos

- Desarrollar un **lenguaje en común**
- Pensar el **fraude como problema de arquitectura**, no solo de modelos predictivos
- Motivar a diseñar **mejores sistemas** antifraude con *machine learning* (ML) y humanos expertos

Vamos a hablar de

- Prevención de fraude
- Arquitectura de software con ML (*ML-enabled software*)
- El rol de analistas expertas en la efectividad del sistema

No es una charla sobre algoritmos, sino sobre diseño de sistemas

Imaginen




Imaginen que..

20 casos entran ahora mismo

- No pueden revisarlos todos
- No pueden bloquearlos todos

¿Qué harían?



El sistema ML los clasifica así

- 10 bajo riesgo
- 5 ambiguos
- 5 alto riesgo




Revisar todo manualmente no escala

Cada caso, en promedio tarda **1 hora** analista en ser procesado.

- Inversión: **20 horas** analista
- **Mayor juicio contextual**





20 hrs



Automatizar demasiado también sale caro

El sistema de ML clasifica cada caso en menos de **1 milisegundo** (ms).

- Inversión: **<1 minuto**
- **Rápido**, sí
- Pero **más fricción** y **más puntos ciegos**



El valor de la detección de fraude es una función del tiempo



Cada minuto de demora puede aumentar el costo del fraude

(Hilal, Gadsden & Yawney, 2022)


La alternativa: combinar ML + analistas

Híbrido: automatizar lo claro y elevar lo ambiguo

- Reducción de 20 a 5 horas de revisión humana
- De **inmediato** accionamos lo crítico

<1 min

Bajo riesgo



Dejar pasar automáticamente

5 hrs


Ambiguos



Enviar a revisión humana

<1 min

Alto riesgo



Retener automáticamente

¿Qué gana la organización con un diseño híbrido?

- **Menos fricción** para usuarios legítimos
- **Mejor uso** del talento experto
- **Menor costo** por demora

Bajo riesgo



Ambiguos



Alto riesgo



Si bloqueas de más, pierdes clientes.



Si bloqueas de menos, pierdes dinero.



Si revisas todo manualmente, no escalas.




Fraude



¿Por qué fraude es especialmente difícil?

- Los atacantes se adaptan
- El fraude es raro y las etiquetas son imperfectas
- Hay que decidir en tiempo real
- El comportamiento cambia con el tiempo
- Además: explicabilidad, privacidad y cumplimiento

El fraude es adversarial: el atacante se adapta




Fraude **no es un problema estático**. Cuando un detector funciona, **los atacantes cambian su estrategia**. Por eso no basta con entrenar un modelo “bueno” una vez

(Bolton & Hand, 2002; Lunghi et al., 2023)

El fraude es raro y las etiquetas son imperfectas


- La mayoría de los casos son legítimos. Eso hace que el problema esté fuertemente **desbalanceado**.
- Muchas veces no hay *labels* perfectos o suficientes para entrenar.



(Hilal, Gadsden & Yawney, 2022; Chen et al., 2025)

Hay que decidir rápido, pero los errores cuestan distinto

- No todos los errores cuestan lo mismo.
- Un falso negativo **deja pasar** fraude real.
- Un falso positivo mete **fricción**, costo operativo y mala experiencia.
- Además, **no hay tiempo infinito** para investigar.



(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022)


No basta con *accuracy*: explicabilidad, privacidad y cumplimiento

- Explicar decisiones
- Respetar regulaciones de privacidad
- Operar bajo controles de gobernanza y auditoría



(Hernandez Aros et al., 2024; Chen et al., 2025)

El fraude no es sólo un problema de predicción; es un problema de **decisión operativa bajo incertidumbre**



Ni reglas, ni ML, ni revisión humana bastan por sí solos

El fraude es un problema de sistema, no de una pieza aislada

Solo reglas

Aportan:

- Respuesta inmediata
- Simplicidad
- Auditabilidad

Pero no bastan:

- Son rígidas
- Se vuelven fáciles de evadir
- Requieren mantenimiento continuo



(Bolton & Hand, 2002; Hilal, Gadsden & Yawney, 2022;
Ding et al., 2023)


Solo *machine learning* (ML)

Aporta:

- Escala
- Velocidad
- Consistencia

Pero no basta:

- Puede ser difícil de explicar
- Es sensible al *drift* y a tácticas nuevas
- Puede aumentar fricción sobre usuarios legítimos



(Hilal, Gadsden & Yawney, 2022; Lunghi et al., 2023;
Chen et al., 2025)

Solo analistas

Aportan:

- Juicio contextual
- Detección de patrones novedosos
- Mejor manejo de la zona gris

Pero no bastan:

- No escala
- Es costoso
- Introducen demoras operativas




(Amershi et al., 2019; Zelvenskiy et al., 2022; Ding et al., 2023; Mosqueira-Rey et al., 2023)

La pregunta ya no es qué componente elegir.
La pregunta es cómo hacerlos **trabajar juntos**.




Un sistema con ML no es solo un modelo

- **ML:** scoring, predicción
- **Software tradicional:** APIs, reglas, integración, gestión de casos
- **Infraestructura/plataforma:** monitoreo, gobernanza, despliegue, automatización



(Sculley et al., 2015; Lewis, Ozkaya & Xu, 2021; Kästner 2025)

En producción, el modelo vive rodeado de infraestructura, operaciones, software convencional y **expertos humanos**



(Sculley et al., 2015; Lewis, Ozkaya & Xu, 2021; Kästner 2025)

Componentes y arquitectura

Los **componentes** se deben de planear en conjunto desde la fase de **arquitectura**, no en secuencia ni de manera aislada.




Figura construida a partir de Lewis, Ozkaya & Xu (2021), de Andersen, & Maalej (2024), y de Kästner (2025)

El humano como componente arquitectónico

- **Asistencia a decisión:** la máquina ayuda a decidir rápido
- **Triage de casos ambiguos:** los casos inciertos se escalan a revisión
- **Aprendizaje continuo:** el *feedback* humano mejora el sistema

El *HIL* no es un parche; es una decisión arquitectónica

(Zelvenskiy et al., 2022; Mosqueira-Rey et al., 2023;
Andersen & Maalej, 2024)

La sinergia entre ML y expertas no es opcional

ML:

- Escala
- Priorización
- Velocidad

→ Prioriza qué mirar

Analistas:

- Contexto
- Validación
- Juicio

→ Corrigen y enseñan

Sistema:

- Nuevas reglas
- Calibración
- Aprendizaje continuo

→ Mejora el siguiente ciclo

El *HIL* en fraude no es una concesión; es una estrategia de desempeño y adaptación

(Chai et al., 2020; Mosqueira-Rey et al., 2023; Ding et al., 2023; Andersen & Maalej, 2024; Yuan et al., 2026)

Patrón *human-in-the-loop* (HIL) para prevención de fraude



Patrones de diseño

Una solución reusable a un problema común dentro de un contexto específico

O una plantilla adaptable para resolver un problema recurrente




(Lakshmanan et al., 2020; Konieczny, 2025)


Patrones de diseño

Recursos


- Reciente interés de expandirlos a la “ciencia de datos”




(Gamma et al., 1995)



(Lakshmanan et al., 2020)



(Konieczny, 2025)



Patrones de diseño

- Adaptables
- Reusables
- Responden a un problema específico
 - Por ejemplo, el fraude ocurre en muchas compañías y productos.
- Nos ahorran tiempo
- Son generales: no proveen detalles de implementación
-



(Lakshmanan et al., 2020; Konieczny, 2025)

Nuestro patrón de diseño

ML-enabled Human-in-the-loop (HIL) Triage



Patrón: *ML-enabled HIL Triage*

- **Problema:** ¿Cómo tomar decisiones antifraude **rápidas** sin sacrificar **juicio** en los casos que más importan?
- **Contexto:** Sistemas donde el volumen supera la capacidad humana, pero automatizar todo introduce puntos ciegos.



ML-enabled Human-in-the-loop Triage

- **Solución:**

Clasificar casos por bandas de riesgo y asociar una política de acción:

- **bajo riesgo** → automatización favorable
- **alto riesgo** → mitigación automática
- **zona gris** → revisión humana



ML-enabled Human-in-the-loop Triage

- **Consecuencias:**

- Mejor uso del talento experto
- Menor fricción innecesaria
- Mayor capacidad de adaptación.
- Complejidad operacional

- **Por qué funciona?**

Alinea cada tipo de decisión con el recurso más adecuado:


- **reglas** → condiciones explícitas
- **ML** → priorización a escala
- **analistas** → incertidumbre contextual





Anatomía del sistema



Arquitectura de referencia del patrón




Arquitectura de referencia del patrón



1 entrada externa
3 Componentes de decisión
3 Acciones posibles


El caso puede nacer dentro o fuera del flujo transaccional



Informe de socio de pago/banco



Esfuerzos automatizados o manuales



Casos judiciales/policiacos (*law enforcement*)




Disputas con clientes





- El sistema recibe señales desde múltiples fuentes
- No todo caso nace de una transacción
- El caso puede originarse por señales internas o externas

Reglas




- **Qué hace:** filtra casos **explícitos** y auditables
- **Por qué importa:** responde rápido y aplica *guardrails*
- **Cuidado:** si dependes demasiado de reglas, se vuelven rígidas y evadibles

Scoring con ML




- **Qué hace:** **destila** múltiples señales en un *score* de riesgo
- **Por qué importa:** prioriza a escala
- **Cuidado:** requiere calibración y monitoreo

Triage




- **Qué hace:** convierte riesgo en acción
- **Por qué importa:** separa score de decisión operacional
- **Cuidado:** los thresholds y políticas también deben gobernarse

Acciones



- Se **reduce la fricción** a usuarios legítimos: inmediato
- Casos ambiguos se envían a **revisión humana**: se tarda
- Bloqueo **inmediato**: mitiga el impacto (🕒). Puede ser cualquier medida de **presión/fricción**

Retroalimentación y mejora continua



- **Analistas** aportan retroalimentación para mejora del sistema
- Nuevas reglas
- Etiquetas revisadas y correcciones para el **sistema ML**


El ML potencia a las analistas; las analistas mejoran al ML

- El **ML** amplifica la capacidad **operativa** de las analistas
- Las **analistas** aportan **feedback experto** para mejorar reglas, umbrales y modelos
- La colaboración reduce fricción innecesaria y mejora el aprendizaje del sistema



No es un modelo aislado.

Es un sistema de decisión con **aprendizaje operativo**.



Del score a la acción y al aprendizaje



El score no decide solo

- El score **resume riesgo**; la política **define la acción**
- Un buen modelo mal integrado produce malas decisiones



Las analistas no son respaldo: son parte del sistema

- Resuelven la **zona gris** y los casos novedosos
- Aportan **juicio contextual** donde el modelo duda
- Su tiempo debe reservarse para casos ambiguos, no para revisar todo
- Su trabajo se conecta mediante **feedback estructurado**
- **Crecen con el sistema:** el contacto con ML abre caminos hacia ciencia de datos



**Invertir en su crecimiento técnico
fortalece el sistema, no solo al equipo**

Ciclo de mejora continua

- La interfaz debe facilitar ***feedback* estructurado**, no solo comentarios libres
- Ese *feedback* puede **reetiquetar casos**, ajustar thresholds y crear nuevas reglas
- Así, la revisión humana mejora tanto el modelo como la política de decisión

Las analistas no sólo resuelven casos;
entrenan al sistema

Trade-offs que sí importan

- Más revisión humana mejora el juicio, pero aumenta **costo y latencia**
- Más automatización escala mejor, pero puede ocultar **errores sistémicos**
- Mayor complejidad arquitectónica exige más **gobernanza y monitoreo**



**El patrón no elimina estos trade-offs; los hace
visibles y gobernables**

Blueprint para llevarse mañana

Diseñar:

- Define resultados esperados y costos de error
- Diseña bandas de riesgo
- Separa *score* de *policy*

Operar:

- Crea la zona de revisión humana
- Monitorea *drift*, falsos positivos y tiempos de revisión
- Define SLAs para la cola de revisión humana

Aprender y gobernar:

- Captura *feedback* estructurado
- Establece gobernanza sobre umbrales, reglas, y acceso a datos

*Diseña, opera,
aprende y gobierna.*

Para cerrar



Cierre

En fraude, automatizarlo todo puede ser tan ingenuo como revisarlo todo a mano.

La ventaja real está en diseñar sistemas donde el ML escala y las analistas entrenan al sistema.

Preguntas



Referencias



Referencias

- Amershi, S., Weld, D., Vorvoreanu, M., Fourney, A., Nushi, B., Collisson, P., Suh, J., Iqbal, S., Bennett, P. N., Inkpen, K., Teevan, J., Kikin-Gil, R., & Horvitz, E. (2019). Guidelines for human-AI interaction. In Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. Association for Computing Machinery. <https://doi.org/10.1145/3290605.3300233>
- ★ Bolton, R. J., & Hand, D. J. (2002). *Statistical fraud detection: A review*. Statistical Science, 17(3), 235–255. <https://doi.org/10.1214/ss/1042727940>
- Chen, Y., Zhao, C., Xu, Y., Nie, C., & Zhang, Y. (2025). Deep learning in financial fraud detection: Innovations, challenges, and applications. Data Science and Management. Advance online publication. <https://doi.org/10.1016/j.dsm.2025.08.002>
- Ding, X., Seleznev, N., Kumar, S., Bruss, C. B., & Akoglu, L. (2023). *From detection to action: A human-in-the-loop toolkit for anomaly reasoning and management*. In Proceedings of the Fourth ACM International Conference on AI in Finance (pp. 279–287). Association for Computing Machinery. <https://doi.org/10.1145/3604237.3626872>

Referencias

- Emergency Nurses Association. (2019). *Sheehy's emergency nursing: principles and practice*. Elsevier Health Sciences.
- Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1995). *Design patterns: elements of reusable object-oriented software*. Pearson Deutschland GmbH.
- Hernandez Aros, L., Bustamante Molano, L. X., Gutierrez-Portela, F., Moreno Hernandez, J. J., & Rodríguez Barrero, M. S. (2024). Financial fraud detection through the application of machine learning techniques: A literature review. *Humanities and Social Sciences Communications*, 11(1), 1–22.
<https://doi.org/10.1057/s41599-024-03606-0>
- Hilal, W., Gadsden, S. A., & Yawney, J. (2022). *Financial fraud: A review of anomaly detection techniques and recent advances*. *Expert Systems with Applications*, 193, 116429. <https://doi.org/10.1016/j.eswa.2021.116429>
- Kádár, T. (2025). The rise of human-in-the-loop fraud prevention: Why analyst-AI collaboration matters. SEON.
<https://seon.io/resources/human-in-the-loop-fraud-detection-and-prevention/>


Referencias

- Kästner, C. (2025). *Machine learning in production: From models to products*. MIT Press. <https://mlip-cmu.github.io/book/>
- Konieczny, B. (2025). *Data engineering design patterns: Recipes for solving the most common data engineering problems*. O'Reilly Media.
- ★ Mosqueira-Rey, E., Hernández-Pereira, E., Alonso-Ríos, D., Bobes-Bascarán, J., & Fernández-Leal, Á. (2023). *Human-in-the-loop machine learning: A state of the art*. *Artificial Intelligence Review*, 56, 3005–3054.
<https://doi.org/10.1007/s10462-022-10246-w>
- Lakshmanan, V., Robinson, S., & Munn, M. (2020). *Machine learning design patterns*. O'Reilly Media.

Referencias


- ★ Lewis, G. A., Ozkaya, I., & Xu, X. (2021). Software architecture challenges for ML systems. In 2021 *IEEE International Conference on Software Maintenance and Evolution (ICSME)*. IEEE. <https://doi.org/10.1109/ICSME52107.2021.00071>
- Lunghi, D., Simitsis, A., Caelen, O., & Bontempi, G. (2023). Adversarial learning in real-world fraud detection: Challenges and perspectives. In *Proceedings of the Second ACM Data Economy Workshop* (pp. 27–33). Association for Computing Machinery. <https://doi.org/10.1145/3600046.3600051>
- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., ... & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28.
- ★ Andersen, J., & Maalej, W. (2024). Design patterns for machine learning-based systems with humans in the loop. *IEEE Software*, 41(4), 151–159. <https://doi.org/10.1109/MS.2023.3340256>
- Yuan, X., Yu, P., Liu, S., Sun, Z., Zhang, Y., & Xu, J. (2026). An expert-in-the-loop framework for unknown attack detection via open-set recognition. *Journal of Computer Security*. Advance online publication. <https://doi.org/10.1177/0926227X251414058>
- ★ Zelvenskiy, S., Harisinghani, G., Yu, T., Ng, E., & Wei, R. (2022). Project RADAR: Intelligent early fraud detection system with humans in the loop. Uber Blog. <https://www.uber.com/en-CR/blog/project-radar-intelligent-early-fraud-detection/>

Una serie de 3 charlas



PyLatam 2026

Están invitad@s!!!



UNIVERSIDAD DE COSTA RICA

2026 • Costa Rica
PYCON LATAM

SÓLVO

CALL FOR PAPERS

¿Tienes una idea, proyecto o experiencia que merece ser compartida? Este es el momento de inspirar, enseñar y conectar con la comunidad Python más grande de Latinoamérica.


¡Tu voz importa!
Registra tu charla en www.pylatam.org

 PyLatam  pylatam  PyLatam  PyLatam

Preparamos esta presentación con:



Canva



GIMP



Google Slides